

Architecture SoftCAM-Transformer — Vue Globale Revisitée

TimeSeriesTransformer HuggingFace + Evidence Layer H1 · d_model=32

ENTRÉES — 4 types de tenseurs

past_values
(B, 422)

contexte 240 min + lags
22 lags (max ≈ 182 min)

past_time_features
(B, 422, 6)

sin/cos heure, jour, semaine
+ log-âge série

past_observed_mask
(B, 422)

masque binaire $\in \{0,1\}$
1 = valeur observée

static_cat_features
(B, 1) ID $\in \{0...4\}$

Embedding(5, emb_dim=2)
→ (B, 2) broadcast (B, 240/120, 2)

future_time_features (B, 120, 6) + **future_values** (B, 120) — TRAINING · teacher forcing
future_values absent à l'inférence (model.generate) · future_time_features toujours disponibles

Projection → d_model=32

ValueEmbed(23→32) $\square$ TimeEmbed(6→32) $\square$ StaticEmbed(2→32) → (B, ctx, 32)

ENCODEUR (inchangé)

4 × [Multi-Head Self-Attention (2 têtes, head_dim=16) → Add&Norm → FFN → Add&Norm]

Entrée : (B, 240, 32) → Sortie : (B, 240, 32)

attention scores : (B, 2, 240, 240) sauvegardés via output_attentions=True [→ H3]

encoder_last_hidden_state (B, 240, 32)

DÉCODEUR (inchangé)

4 × [Masked Self-Attn → Add&Norm → Cross-Attn (Q=déc, K=V=enc) → Add&Norm → FFN → Add&Norm]

Entrée déc : (B, 120, 32) + enc K,V : (B, 240, 32) → Sortie : (B, 120, 32)

decoder_last_hidden_state (B, 120, 32)

$\square$ EVIDENCE LAYER (nouauté H1)

Calcul des poids d'évidence

Linear(d_model=32 → ctx=240)

→ Softmax(dim=-1)

→ M (B, 120, 240)

Régularisation ElasticNet (ajoutée à la loss)

$\square = \square_{\text{forecast}} + \alpha \|\mathbf{M}\|_1 + \beta \|\mathbf{M}\|_2^2$

L1 → poids parcimonieux (peu de positions clés)

L2 → lissage (éviter les pics isolés)

CARTE D'ÉVIDENCE M (B, 120, 240)

M[t, s] = importance du pas s du contexte
pour prédire le pas futur t

→ l'EXPLICATION, produite gratuitement en 1 forward pass

EXPLICATION
fidèle

COMBINAISON LINÉAIRE

$h[t] = \sum_s M[t,s] \times \text{encoder_embeddings}[s]$

enc_emb (B,240,32) × M (B,120,240) → h (B,120,32)

parameter_projection — Linear(32 → 3)

→ (B, 120, 3) : loc, scale, df de la distribution StudentT

PRÉDICTION

StudentT → 100 échantillons → médiane

(B, 100, 120) → médiane (B, 120)

encoder_embeddings (B,240,32) → combinaison linéaire

Légende

- Composant standard TimeSeriesTransformer (inchangé vs FAYAM)
- Représentation latente (embeddings) — espace d_model=32
- Nouveauté H1 — Evidence Layer (remplace parameter_projection directe)
- Combinaison interprétable : prédiction = formule explicite ($\sum$ poids × contexte)
- Explication gratuite — 1 forward pass = prédiction + carte d'évidence

Différence clé : H1 vs TFT

TFT (Lim et al. 2019) : interprétabilité par attention
→ attention ≠ explication (Jain & Wallace 2019)
H1 SoftCAM-Transformer : combinaison linéaire exacte
→ fidélité par construction (M est le calcul, pas une approximation post-hoc)

Hypothèses à valider sur Cluster 4 :

H1.A : M pointe les heures pic (17h-19h) et creux (2h-6h)
H1.B : lags 1440/2880 dominants dans cross_attentions
H1.C : $R^2 \geq 0.30$, Spearman ≥ 0.85 conservés après Evidence Layer