

Zoom Décodeur — TimeSeriesTransformer

prediction_length=120 · d_model=32 · n_heads=2 · decoder_layers=4

encoder_last_hidden_state
(B, 240, 32)

issu de l'encodeur
→ K et V de la
cross-attention
(240 positions de contexte)

K, V →

future_values
(B, 120)

TRAINING uniquement

absent à l'inférence (model.generate)

future_time_features
(B, 120, 6)

features temporelles
des 120 pas futurs
connues à l'avance (horaire, jour...)

static_cat (réutilisé)
(B, 2) → (B, 120, 2)

même embedding que
l'encodeur, partagé
→ Linear(2→32) → (B,120,32)

Embedding décodeur : future_values + lags + time_features + static → Linear → □

decoder_input : (B, 120, 32)

COUCHE DÉCODEUR — détail couche 1/4 (×4 couches identiques)

entrée : (B, 120, 32) + encoder K,V (B, 240, 32) → sortie : (B, 120, 32)

A — Masked Multi-Head Self-Attention (causal — le pas t ne voit que les pas 0...t-1)

Q = Linear(32→32)

(B,120,32) → (B,2,120,16)

K = Linear(32→32)

(B,120,32) → (B,2,120,16)

V = Linear(32→32)

(B,120,32) → (B,2,120,16)

Scores = softmax($QK^T/\sqrt{16}$ + mask)

→ (B, 2, 120, 120)

masque triangulaire inférieur — causal
Output Scores×V→concat→(B,120,32)

Résidu + LayerNorm → (B, 120, 32)

B — Cross-Attention (Q = décodeur, K = V = encodeur)

chaque pas futur t interroge les 240 positions du contexte passé

Q = Linear(32→32)

depuis décodeur (B,120,32)
→ (B, 2, 120, 16)

K = Linear(32→32)

depuis encodeur (B,240,32)
→ (B, 2, 240, 16)

V = Linear(32→32)

depuis encodeur (B,240,32)
→ (B, 2, 240, 16)

Scores = softmax($QK^T/\sqrt{16}$)

(B, 2, 120, 240)

□ cross_attentions sauvegardés
(output_attentions=True)
ligne t = poids sur les 240 pos.
de contexte pour prédire step t
→ matière première de H3

Output : Scores × V → concat → Linear(32→32)
→ (B, 120, 32)

Résidu + LayerNorm → (B, 120, 32)

C — FFN : Linear(32→32) → GELU → Linear(32→32)
→ (B, 120, 32)

Résidu + LayerNorm → (B, 120, 32)

× 3 couches identiques (couches 2 / 3 / 4)

decoder_last_hidden_state

(B, 120, 32)

→ 120 représentations latentes — une par pas de prédiction — entrent dans la tête de sortie