

Zoom Tête de Sortie — Siège du Module d'Explicabilité H1

Ce qui change par rapport à FAYAM : `parameter_projection` → Evidence Layer + combinaison linéaire

`decoder_last_hidden_state`
(B, 120, 32)

FAYAM (original)

Chemin FAYAM — boîte noire

`parameter_projection`
`Linear(32 → 3) → (B, 120, 3)`

Distribution StudentT
`loc (B, 120, 1) ← moyenne`
`scale (B, 120, 1) ← écart-type`
`df (B, 120, 1) ← degrés lib.`

Échantillonnage × 100
(B, 100, 120)

Prédiction
(B, 100, 120) — médiane finale

Explication ?
❑ **ABSENT**
`parameter_projection` est une
combinaison non-linéaire opaque

Comparaison FAYAM vs SoftCAM-Transformer

FAYAM : (B,120,32) → `Linear(32→3)` → StudentT → prédiction [opaque]

H1 : (B,120,32) → `Linear(32→240)+Softmax` → M (B,120,240)

→ $\sum M \times \text{enc_emb}$ → `Linear(32→3)` → StudentT → prédiction + explication

Coût d'explication = 0 (1 seul forward pass produit prédiction ET carte d'évidence)

Fidélité par construction : M[t,s] est le poids RÉEL utilisé pour calculer `pred[t]`

Critère de non-dégradation H1.C (à valider expérimentalement)

$R^2 \geq 0.30$ et Spearman ≥ 0.85 conservés après ajout de l'Evidence Layer (vs FAYAM : $R^2=0.37$, Spearman=0.92)

H1 SoftCAM-Transformer ❑

❑ H1 — Evidence Layer (nouveauité)

`evidence_linear`
`Linear(d_model=32 → ctx=240)`
→ (B, 120, 240) [logits bruts]

`Softmax(dim=-1)`
somme = 1 par ligne t

CARTE D'ÉVIDENCE
M (B, 120, 240)

M[b, t, s] = importance du pas s
du contexte pour prédire le pas t
→ L'EXPLICATION, lisible directement

Régularisation ElasticNet sur M

$\| \square \|_{\text{elastic}} = \alpha \| M \|_1 + \beta \| M \|^2$

L1 → parcimonie · L2 → lissage temporel

Combinaison linéaire
 $h[t] = \sum_s M[t,s] \cdot \text{enc_emb}[s]$
`enc_emb (B,240,32) → h (B,120,32)`
→ représentation enrichie par le contexte

`parameter_projection`
`Linear(32→3) → (B,120,3)`

StudentT → sample × 100
Prédiction (B, 100, 120)
+ Carte d'évidence M (B, 120, 240)

`encoder_embeddings`
(B, 240, 32)
sortie de l'encodeur réutilisée ici