

Les Séries Temporelles : de la Prédiction à l'Explicabilité

Cabrel FOSSO

11 avril 2026



Plan de la présentation

- 1 Introduction
- 2 Exemples d'application
- 3 Structure et composantes
- 4 Enjeux des séries temporelles
- 5 Modélisation
- 6 Explicabilité
- 7 Perspectives & Travaux futurs

Qu'est-ce qu'une série temporelle ?

1. Définition Statistique

(Box & Jenkins, 1970)

« Une suite d'observations d'une variable quantitative recueillies à des instants successifs, généralement espacés régulièrement, où l'ordre temporel et la dépendance entre observations sont fondamentaux. »

2. Définition Informatique

(Chatfield, 2003)

« Un ensemble de données indexées par le temps, utilisées pour l'analyse, la prévision et la détection de motifs temporels dans divers domaines applicatifs. »

3. Définition Conceptuelle

« La trace numérique laissée par l'évolution d'un phénomène observable, capturant sa dynamique intrinsèque à travers le prisme du temps. »

Caractéristique fondamentale :


La dépendance temporelle entre observations successives

Secteurs utilisant les séries temporelles :

1. **Cloud Computing** : Gestion du *cold start* FaaS
2. **Finance** : Prédiction des cryptomonnaies (Binance)
3. **Santé** : Monitoring des signes vitaux (ECG, température)
4. **Énergie** : Prédiction de la consommation électrique
5. **Réseaux** : Analyse du trafic internet
6. **Transport** : Prédiction de la demande (Uber, aviation)

...et bien d'autres domaines encore

Cloud Computing : Série Temporelle des Appels FaaS




Ex : Série temporelle des appels AWS Lambda

Finance : Série Temporelle du Bitcoin



Ex : Cours BTC/USDT sur coingecko (données réelles)

Énergie : Série Temporelle de Consommation



Ex : Charge électrique nationale

Éléments clés d'une série temporelle :

1. Tendence (Trend)

- Évolution générale à long terme
- Ex : Croissance économique, usure d'une machine


2. Saisonnalité (Seasonality)

- Variations périodiques régulières
- Ex : Pics de consommation électrique en hiver

3. Bruit (Noise)


- Composante aléatoire imprévisible
- Ex : Variations quotidiennes inexplicables

Exemple : Série temporelle des passagers aériens




Série temporelle des passagers aériens aux USA (1994-1997)

Exemple : Composante tendancielle




Composante tendancielle

Exemple : Composante saisonnière



Composante saisonnière

Exemple : Composante résiduelle



Composante résiduelle

Domaines clés et leurs défis :

1. Cloud Computing

- Problème : Cold start des fonctions FaaS
- Prédiction : charge future pour préchauffage

2. Finance & Crypto

- Problème : volatilité des marchés
- Prédiction : tendances de prix futurs

3. Énergie

- Problème : équilibre offre/demande
- Prédiction : consommation électrique future

Prévoir = Mieux décider

Maintenant que nous savons *POURQUOI* prédire. . .

Comment prédire ?

- La prédiction nécessite une **compréhension** du phénomène
- Cette compréhension passe par la **modélisation**
- Différents types de modèles selon le phénomène

« Pour prévoir l'avenir, il faut d'abord comprendre le présent »

Deux approches de modélisation

Modèles Déterministes

Le monde prévisible

- Phénomènes régis par des lois fixes
- Aucune place pour l'aléatoire
- Ex : Mouvement planétaire, trajectoire d'une balle
- Formules exactes, résultats certains

Modèles Stochastiques

Le monde probabiliste

- Intègre l'incertitude et le hasard
- Donne des prévisions avec intervalles de confiance
- Ex : Météo, marchés financiers, trafic internet
- Plus réaliste mais moins certain

1. Régression Linéaire/Polynomiale

- Approximation par droites ou courbes polynomiales
- Ex : $y = ax + b$ ou $y = ax^2 + bx + c$

2. Décomposition de Fourier

- Représentation en séries de sinus/cosinus
- Idéal pour signaux périodiques purs

3. Modèles Additifs/Multiplicatifs

- Combinaison des composantes (Tendance + Saisonnalité + Bruit)
- Additif : $Y = T + S + \text{Bruit}$
- Multiplicatif : $Y = T \times S \times \text{Bruit}$
- Mixte : $Y = T \times S + \text{Bruit}$

4. Lissage Exponentiel Simple

- Pondération décroissante des observations passées
- Bon pour séries sans tendance ni saisonnalité

Pourquoi les Modèles Déterministes Ne Suffisent Pas

La réalité est désordonnée

- Marchés financiers : paniques, bonnes surprises
- Trafic internet : viralité imprévisible
- Consommation énergétique : météo, aléas
- Santé : variabilité individuelle

Besoin d'outils plus réalistes

Les modèles stochastiques acceptent l'incertitude comme partie intégrante

1. AR (AutoRegressif)

- La valeur future dépend des **valeurs passées**
- Ex : $X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t$

2. MA (Moyenne Mobile)

- La valeur future dépend des **erreurs passées**
- Ex : $X_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$

3. ARMA = AR + MA

- Combine valeurs passées ET erreurs passées
- Pour séries **stationnaires**

4. ARIMA = ARMA + Intégration

- Ajoute la **différenciation** pour séries non-stationnaires
- Gère les tendances

5. SARIMA = ARIMA + Saisonnalité

- Composante saisonnière ajoutée
- Pour données avec cycles périodiques

Approches neuronales pour séries complexes

6. RNN (LSTM / GRU)

- Réseaux avec mémoire pour séquences longues
- LSTM : Gère les dépendances à long terme
- Idéal pour patterns temporels complexes

7. Transformers

- Attention mechanism pour dépendances globales
- Capture relations à toutes les échelles de temps
- State-of-the-art en prévision longue

8. Modèles Hybrides

- Combinaison ARIMA + LSTM
- Modèles à base d'attention temporelle
- Meilleur des deux mondes

Une prédiction sans explication est un chiffre sans conviction

Questions cruciales que l'explicabilité permet de résoudre :

- **Quels moments passés** ont vraiment influencé la prédiction ?
- **Quelle composante** (tendance, saisonnalité, cycle) a été déterminante ?
- Le modèle a-t-il appris un **pattern réel** ou un **artefact spécifique** ?
- **Pourquoi** cette prédiction plutôt qu'une autre ?

Sans réponses à ces questions, la prédiction reste un acte de foi

Modèles Déterministes : Facilement Explicables

- Formules mathématiques **transparentes**
- Relations de cause à effet **directes**
- Ex : $y = 2x + 3 \rightarrow$ "Si x augmente de 1, y augmente de 2"
- On sait **POURQUOI** le modèle prédit ce qu'il prédit

Mais tous les modèles ne sont pas aussi faciles à expliquer :

Les modèles de séries temporelles — comme les LSTM ou Transformers — capturent des dépendances complexes entre les événements passés et présents. Cependant, ils sont souvent perçus comme des *"boîtes noires"* étant donné les milliers de paramètres imbriqués et les relations non linéaires et complexes.

Ces approches ne dépendent pas du type de modèle : elles s'appliquent à n'importe quelle méthode d'apprentissage, même si celle-ci est une “boîte noire”.

- **SHAP** (Lundberg & Lee, 2017) — mesure la contribution moyenne de chaque variable ou instant à la prédiction, comme dans un “partage équitable” de la responsabilité d'une décision.
- **LIME** (Ribeiro et al., 2016) — crée un petit modèle simple autour d'une prédiction complexe pour expliquer localement le comportement du modèle.
- **Permutation Importance** — mélange les valeurs d'une variable pour voir si la performance du modèle chute ; si oui, cette variable est importante.
- **Partial Dependence Plot (PDP)** — montre comment la prédiction évolue quand une variable change, tout en gardant les autres constantes.

Ces approches utilisent les structures internes du réseau pour révéler quelles parties de la séquence ont le plus influencé la sortie.

- **Attention Mechanisms** (Bahdanau et al., 2015 ; Vaswani et al., 2017) — attribuent un poids d'attention à chaque pas de temps : plus le poids est élevé, plus le modèle a “regardé” cet instant pour sa décision.
- **Saliency Maps** (Simonyan et al., 2013) — visualisent la “sensibilité” du modèle : si une petite variation d'un point temporel change fortement la prédiction, alors ce point est important.
- **Integrated Gradients** (Sundararajan et al., 2017) — cumulent les effets du gradient entre une entrée de référence (neutre) et l'entrée réelle, pour donner une importance plus stable et plus juste à chaque instant.

Ces méthodes tiennent compte de la structure temporelle des données : elles expliquent non seulement *quoi* a influencé le modèle, mais aussi *quand*.

- **TimeSHAP** (Bento et al., 2021) — prolonge SHAP aux séquences : il supprime ou modifie des événements passés pour voir leur impact sur la prédiction présente.
- **WindowSHAP** (Nayebi et al., 2022) — découpe la série en fenêtres temporelles pour expliquer des segments entiers plutôt que des points isolés, ce qui accélère le calcul et garde du sens temporel.
- **ShaTS** (2025) — une approche plus récente qui conserve les dépendances temporelles et produit des explications plus cohérentes pour des modèles comme LSTM ou Transformer.

Comparaison des Méthodes d'Explicabilité Temporelle

Pour mieux choisir une méthode d'explicabilité, il est essentiel de comprendre :

- le type de modèle qu'elle vise (générique, séquentiel, profond, etc.) ;
- ses points forts (interprétabilité, fidélité, coût, stabilité) ;
- ses limites (scalabilité, dépendance au modèle, précision temporelle).

Les trois prochains tableaux résument ces aspects pour les principales approches.

Comparaison : Méthodes Modèle-Agnostiques

Méthode	Type de modèle ciblé	Points forts	Limites / défis
SHAP (Kernel-SHAP et DeepSHAP)	Tout modèle	Interprétation cohérente et robuste; approche théorique solide; implémentations stables (Lundberg & Lee, 2017).	Très coûteux sur séries longues; ne tient pas compte de la dépendance temporelle.
LIME	Tout modèle	Simple à comprendre; rapide; bon pour explorer des prédictions ponctuelles (Ribeiro et al., 2016).	Résultats parfois instables; ne capture pas les dépendances temporelles complexes.

Ces méthodes sont idéales pour des modèles statiques ou des séries courtes, mais limitées dès que la structure temporelle devient importante.

Comparaison : Méthodes Spécialisées pour Séries Temporelles

Méthode	Type de modèle ciblé	Points forts	Limites / défis
TimeSHAP	RNN, LSTM, GRU	Explique l'impact des instants passés sur la prédiction actuelle ; respecte la séquence temporelle (Bento et al., 2021).	Calculs lourds sur longues séquences ; dépend des choix de "pruning".
WindowSHAP	Modèles séquentiels ou classificateur.	Regroupe les données en fenêtres temporelles : explications plus compactes et rapides (Nayebi et al., 2022).	Perte de précision au niveau fin ; choix de la taille de fenêtre non trivial.

Ces approches respectent la dynamique temporelle et conviennent bien aux modèles séquentiels (RNN, LSTM).

Comparaison : Méthodes Récentes et Émergentes

Méthode	Type de modèle ciblé	Points forts	Limites / défis
ShaTS	Séries temporelles (tous modèles)	Préserve les dépendances temporelles ; explications plus cohérentes et précises (2025).	Méthode récente, encore peu utilisée ; validation empirique limitée.

Synthèse :

- SHAP / LIME → bons points de départ mais pas temporels.
- TimeSHAP / WindowSHAP → meilleure fidélité temporelle, coût plus élevé.
- ShaTS → compromis prometteur entre précision et dépendance temporelle.

Des outils puissants... mais une question clé

Points critiques

- Comment valider la **véracité** des explications ?
- L'explicateur devient-il lui-même une **boîte noire** ?
- La stabilité des explications (un petit bruit, une explication très différente) ?

Limites intrinsèques

- Rendre interprétables les modèles comme LSTM = "régression linéaire" ? souvent impossible
- Illusion de compréhension : explication plausible mais erronée
- Peut-on **faire mieux** ?

L'explicabilité n'est pas une panacée — c'est un défi scientifique ouvert.

Ce que je compte faire / explorer :

1. Étude approfondie des trois modèles principaux :

- **SARIMA** : historique, hypothèses statistiques, forces/limites
- **LSTM** : architecture réseau neuronal, gestion de la mémoire temporelle
- **Transformers** : mécanisme d'attention, adaptation aux séries temporelles

2. Ouverture des "boîtes noires" :

- Comprendre les entrées/sorties de chaque modèle
- Analyser ce que chaque architecture résout concrètement
- Identifier pourquoi choisir un modèle plutôt qu'un autre

3. Apprentissage par l'expérimentation :

- Implémentation pratique et tests comparatifs
- Application sur datasets réels pour validation empirique
- Acquisition d'une intuition concrète du fonctionnement

Objectif : Cette compréhension approfondie comme prérequis essentiel avant d'aborder les méthodes d'explicabilité temporelle.

Merci pour votre attention !

Des questions ?