

Foundation Models for Time Series: A Survey

Cabrel FOSSO

13 décembre 2025

Qu'est-ce qu'un Modèle de Fondation ?

- 1. Définition Générale** Un modèle de fondation est un modèle d'IA puissant, pré-entraîné sur de vastes ensembles de données pour capturer des patterns généraux, puis adapté (fine-tuné) à des tâches spécifiques.
- 2. Analogie avec le Traitement du Langage Naturel (NLP)** Pensez à ChatGPT ou GPT : entraîné sur des milliards de textes pour comprendre le langage humain, puis fine-tuné pour des tâches comme rédiger un email ou coder. C'est similaire pour les séries temporelles !
- 3. Application aux Séries Temporelles** Pré-entraînement sur des données temporelles massives (finance, santé, etc.), puis affinage pour prévision, anomalies, etc. Avantages : généralisation, efficacité sur peu de données.

Caractéristique clé : Apprendre des représentations généralisables pour une adaptation rapide.

Plan de la présentation

- 1 Introduction aux Modèles de Fondation
- 2 Enjeux et Domaines d'Application des Séries Temporelles
- 3 Flashback Historique
- 4 Modèles de Fondation en Profondeur

Secteurs utilisant les séries temporelles :

1. **Finance** : Prévion des prix des actions, détection d'anomalies de marché.
2. **Santé** : Monitoring des signes vitaux, prévision d'épidémies.
3. **Énergie** : Prévion de la demande, optimisation des ressources.
4. **Transports** : Prévion du trafic, gestion de flotte.
5. **IoT et Industrie** : Analyse de capteurs, maintenance prédictive.

Importance : Capturer dépendances temporelles pour des décisions informées.

Défis principaux :

1. **Nature Séquentielle** : Dépendances courtes/longues, non-indépendance des données.
2. **Multivarié** : Interactions entre variables (ex. : cœur, pression artérielle).
3. **Irrégularités** : Données manquantes, échantillonnage irrégulier.
4. **Bruit et Non-Stationnarité** : Fluctuations aléatoires, propriétés changeantes.
5. **Haute Dimensionnalité** : Séquences longues, défis computationnels.

Enjeu clé : Anticiper le futur avec précision malgré l'incertitude.

- **Avantages :**

- Simples et interprétables : Basées sur des formules statistiques claires (ex. : Moyennes Mobiles pour lisser tendances).
- Efficaces pour données linéaires : ARIMA modélise dépendances temporelles courtes via AR (valeurs passées) et MA (erreurs passées).
- Faibles coûts computationnels : Idéales pour petits datasets ou analyses rapides.

- **Limites :**

- Lutte avec non-linéarités : Ne capturent pas patterns complexes ou irréguliers (ex. : données multivariées volatiles).
- Assument stationnarité : Données doivent avoir moyenne/variance stables, restrictif pour scénarios réels.
- Difficulté avec haute dimension : Peinent sur longues séquences ou dépendances longues ; ex. : ARIMA échoue sur non-stationnaires.

Exemple : ARIMA pour prévision, mais nécessite prétraitement pour tendances/saisonnalités.

Réseaux de Neurones Récurents (RNN)

- **Avantages :**

- Capturent dépendances temporelles : Via états cachés qui retiennent infos passées (ex. : prédiction stock influencée par jours précédents).
- Apprentissage end-to-end : Extraient features directement des données brutes, sans ingénierie manuelle.
- Adaptés aux séquences : Idéals pour tâches comme prévision ou analyse de capteurs.

- **Limites :**

- Vanishing gradients : Gradients s'évanouissent sur longues séquences via BPTT, rendant difficile l'apprentissage de dépendances longues.
- Séquentiel : Traitent données étape par étape, non parallélisable, augmentant temps d'entraînement.
- Contraintes mémoire/overfitting : Coûts élevés sur grands datasets ; risque d'overfitting sur petits.

Transition : Besoin de mieux gérer dépendances longues et gradients → LSTM/GRU avec gates.

- **Avantages :**

- Gates pour mémoire longue : LSTM (1997) utilise input/output/forget gates pour retenir/oublier infos ; GRU (2014) simplifié avec reset/update pour efficacité.
- Mitigent vanishing gradients : Mieux capturent dépendances longues vs. RNN basiques (ex. : prévision stocks ou énergie).
- Performants sur tâches complexes : Reconnaissance vocale, traduction, time series forecasting ; moins de params pour GRU.

- **Limites :**

- Toujours séquentiel : Non parallélisable, temps d'entraînement long sur grandes seqs.
- Coûts mémoire/compute : Hauts sur datasets massifs ; encore vanishing/exploding gradients sur extrêmes.
- Lutte avec très longues séquences : Patterns irréguliers ou overfitting sur petits data.

Problème résolu : Vanishing gradients vs. RNN, mais scalabilité faible → besoin de parallélisme.

Les Transformers (2017)

- **Avantages :**

- Self-attention pour dépendances longues/globales : Capture relations distantes sans récurrence (ex. : saisonnalité sur mois).
- Parallélisme et scalabilité : Traitent séquences entières simultanément, plus rapide sur GPU/TPU.
- Surpassent RNN : Meilleurs pour forecasting/anomalies ; gèrent haute dimension.

- **Particularités :**

- Processent séquences entières simultanément : Via Q/K/V matrices (équation : $Attention(Q, K, V) = softmax(QK^T / sqrt(d_k))V$).
- Lient séries multiples (multivarié) : Capturent interactions inter-variables (ex. : santé : cœur/pression).

- **Exemples** : TST (Time Series Transformer), Informer pour longues seqs et irrégularités.

Shift paradigmatique : De récurrent/séquentiel à attention-based/global.

Comment les Foundation Models Changent la Donne

1. Apprennent patterns partagés sur datasets massifs :

- Pré-entraînement sur vastes données diversifiées (ex. : finance, santé, énergie) pour capturer dépendances temporelles communes.
- Contrairement aux modèles individuels par série, exploitent similitudes cross-séries pour robustesse.

2. Généralisation cross-domain, efficacité sur low-data :

- Transférabilité : Apprennent de domaines hétérogènes, adaptables à tâches non vues avec peu de données étiquetées.
- Réduit overfitting : Performants sur small datasets via affinage, idéal pour scénarios réels limités en data.

3. Exemples : TST (adapté pour time series), Informer (scalabilité longues seqs), PatchTST (patches pour patterns locaux/globaux).

Avantage clé : Framework unifié pour tâches diverses (prévision, anomalies, classification).

Taxonomie des Modèles

Idee générale : Une classification structurée des modèles de fondation pour séries temporelles, pour comparer et organiser selon plusieurs dimensions clés (inspiré de l'article pour identifier tendances et lacunes).

- **Architecture** : Structure du modèle (ex. : encoder-only pour extraire features ; decoder-only pour génération séquentielle).
- **Patch vs. Non-Patch** : Basé sur segmentation en "patches" (fenêtres) pour patterns locaux, ou traitement brut de la séquence.
- **Objectif** : Fonction de perte d'entraînement (ex. : MSE pour précision point ; NLL pour incertitude probabiliste).
- **Univarié/Multivarié** : Gère une variable unique ou plusieurs avec interactions.
- **Probabiliste** : Fournit distributions/incertitudes ou prédictions fixes.
- **Échelle** : Taille/complexité (léger pour ressources limitées ; large-scale pour généralisation).

But : Adresser manque de cadre détaillé dans littérature ; guide recherche future.

Idée générale : Détaille et compare des modèles de fondation selon la taxonomie (architecture, etc.), en mettant l'accent sur leurs innovations pour time series tasks comme forecasting ; inclut tailles, datasets et adaptations.

- **Non-Transformer** : Tiny Time Mixers (TTM) - Modèle léger pour forecasting multivarié ; patching adaptatif, scalabilité.
- **Encoder-Decoder** : TimeGPT - Combine LLM/CNN pour univarié ; pré-entraînement massif, zéro/few-shot.
- **Encoder-Only** : MOMENT (masquage patches pour features) ; MOIRAI (probabiliste multivarié avec attention flexible).
- **Decoder-Only** : Timer-XL (TimeAtten pour causalité) ; Time-MOE (MoE pour scalabilité multi-résolution).
- **Adaptation LLM** : Chronos (tokenisation probabiliste) ; AutoTimes (LLM pour multivarié avec segments).

Limitations communes :

1. Scalabilité pour longues séquences :

- Coût $O(n^2)$ en self-attention ; difficile pour très longues data (ex. : millions de points).
- Solutions émergentes : Attention éparse ou linéaire, mais pas toujours implémentées.

2. Manque de support probabiliste/multivarié dans certains :

- Pas d'incertitude ou multivarié natif (ex. : TTM point-only ; TimeGPT univarié).
- Limite gestion risques ou interactions variables complexes.

3. Coûts computationnels élevés :

- Grands modèles (ex. : 2.4B params) exigent GPU/TPU massifs ; pas adaptés à low-resource.
- Accumulation erreurs en autoregressif pour long-term.

Défis pour recherche future : Hybrides, interprétabilité, scalabilité.

1. Transformers comme paradigme dominant pour time series.
2. Foundation models offrent scalabilité et généralisation.
3. Perspectives : Hybrides, interprétabilité, multi-modal.

Contribution : Taxonomie pour guider chercheurs et praticiens.

Merci pour votre attention !

Des questions ?