

Explicabilité et Interprétabilité en Intelligence Artificielle : Fondations, Méthodes et Enjeux Éthiques

Vers une IA de confiance et transparente

Cabrel FOSSO

17 avril 2026



Plan de la présentation

- 1 Introduction et Problématique
- 2 Clarification Conceptuelle
- 3 Taxonomie des Méthodes XAI
- 4 Évaluation et Principes Directeurs
- 5 Cas pratique et enjeux
- 6 Limites et Critiques
- 7 Perspectives et Conclusion

L'essor de l'IA et le problème de la « boîte noire »

Le paradoxe de la performance

Les modèles d'apprentissage profond (Deep Learning) atteignent des performances remarquables, mais leur complexité les rend de plus en plus opaques.

La « Black-box » :

1. Des réseaux de neurones avec des **milliards de paramètres**
2. Des modèles d'ensemble (Random Forest, Gradient Boosting)
3. Des architectures complexes (Transformers, LSTM)

Plus un modèle est performant, plus il devient opaque (1)

Citation source : « **L'opacité des modèles complexes compromet la confiance et la fiabilité des systèmes d'IA** » (2)

Le problème de la boîte noire en détail

1. Complexité extrême

- Réseaux de neurones profonds (Deep Neural Networks)
- Modèles ensembles (Random Forest, XGBoost)
- Modèles avec des milliards de paramètres (GPT, LLaMA)

2. Conséquence majeure

- Même les concepteurs ne comprennent pas toujours comment une prédiction spécifique est atteinte
- Impossible de tracer le cheminement logique complet

3. Risques critiques

- Biais invisibles (discrimination raciale, sexiste, etc.)
- Manque de redevabilité (accountability)
- Erreurs indétectables dans des domaines sensibles

Domaines à risque

Santé, Justice, Finance, Recrutement, Véhicules autonomes

Pourquoi l'XAI est-elle nécessaire ? (Les Desiderata)

Les 4 piliers de l'XAI

1. Confiance (Trust)

- S'assurer du bon fonctionnement en déploiement
- Valider la robustesse du modèle

2. Causalité

- Distinguer corrélation et causalité
- Éviter les relations fallacieuses

3. Éthique et Justice

- Garantir l'absence de discrimination
- Promouvoir une IA équitable

4. Conformité réglementaire

- RGPD et « droit à l'explication »
- Obligations légales dans la finance

Sans explicabilité, l'IA reste une boîte noire que personne ne peut véritablement contrôler.

Interprétabilité vs Explicabilité

Interprétabilité (Interpretability)

Définition : Capacité intrinsèque à comprendre la **mécanique interne** et la **logique du modèle** (le « *comment* »).

Pour qui ? Principalement pour les **experts IA** et les **développeurs**.

Exemple : Comprendre comment un arbre de décision partitionne l'espace des features.

Explicabilité (Explainability)

Définition : Capacité à **communiquer les raisons** d'un résultat en langage compréhensible par l'humain (le « *pourquoi* »).

Pour qui ? Principalement pour les **utilisateurs finaux** et les **parties prenantes**.

Exemple : Expliquer pourquoi un patient a été diagnostiqué à risque.

Analogie : L'interprétabilité est pour les mécaniciens (comment fonctionne le moteur) ; l'explicabilité est pour le conducteur (pourquoi la voiture s'arrête).(3)

Transparence intrinsèque vs Explications Post-hoc

Transparence / Ante-hoc

Modèles intrinsèquement interprétables

- Arbres de décision
- Régression linéaire/logistique
- Règles d'association

Avantage : Compréhension directe et fidèle

Limite : Performance souvent inférieure

Post-hoc

Méthodes appliquées après entraînement

- SHAP, LIME
- Grad-CAM
- Attention Mechanisms

Avantage : Applicable à tout modèle

Limite : Risque d'infidélité

« Une explication post-hoc n'est qu'une approximation du modèle réel — elle peut être trompeuse. »

1. Par portée (Scope)

- **Globale** : Expliquer le comportement général du modèle sur tout le dataset
- **Locale** : Expliquer une prédiction spécifique pour une instance donnée

2. Par dépendance au modèle (Model dependency)

- **Modèle-agnostique** : S'applique à tout type de modèle (SHAP, LIME)
- **Modèle-spécifique** : Exploite l'architecture interne (Grad-CAM pour CNN)

3. Par résultat produit

- Importance des features
- Règles de décision
- Visualisations (heatmaps, saliency maps)
- Explications textuelles ou contre-exemples

Régression Linéaire/Logistique

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \varepsilon$$

- Poids des variables directement lisibles
- Signe et magnitude donnent l'influence

Arbres de Décision

- Logique « Si-Alors » facile à suivre
- Visualisation directe du cheminement

Limites importantes

- Performances souvent inférieures aux modèles complexes
- Perdent leur « simulatabilité » si trop de variables
- Difficilement applicables aux données non structurées (images, texte)

« Un modèle linéaire avec 1000 features n'est plus interprétable par un humain » (4)

LIME (Local Interpretable Model-agnostic Explanations)

Ribeiro et al., 2016 (5)

Principe :

- Approximation locale par un modèle simple (ex : linéaire)
- Autour d'une prédiction spécifique à expliquer
- Génère des variations de l'instance originale

Avantages :

- Très rapide et intuitif
- Modèle-agnostique
- Bon pour l'exploration ponctuelle

Inconvénients :

- Instabilité des résultats
- Ne capture pas les dépendances complexes

SHAP (SHapley Additive exPlanations)

Lundberg & Lee, 2017 (6)

Principe :

- Basé sur la théorie des jeux coopératifs
- Valeurs de Shapley pour distribution équitable
- Importance de chaque feature = contribution marginale moyenne

Avantages :

- Solide fondement théorique
- Cohérence globale et locale
- Propriétés mathématiques désirables (additivité, symétrie)

Inconvénients :

- Très coûteux computationnellement
- Complexité exponentielle dans le cas général

Comparaison LIME vs SHAP

Caractéristique	LIME	SHAP
Fondement théorique	Approximation locale	Valeurs de Shapley (théorie de jeux)
Vitesse d'exécution	Rapide	Lent (sauf approximations)
Stabilité des explications	Peu stable	Stable et cohérent
Propriétés mathématiques	Limitées	Additivité, consistance, symétrie
Meilleur usage	Exploration rapide	Analyse fiable et rigoureuse

« SHAP est plus stable et théoriquement fondé ; LIME est plus rapide et intuitif » (7)

Grad-CAM (Gradient-weighted Class Activation Mapping)

Selvaraju et al., 2017 (8)

Principe :

- Utilise les gradients de la dernière couche convolutive
- Produit une carte de chaleur (heatmap)
- Identifie les régions importantes pour la décision

Objectif :

- Visualiser quelles zones de l'image ont influencé la prédiction
- Ex : pixels d'une tumeur, contour d'un objet

Applications :

- Vision par ordinateur
- Diagnostic médical sur images
- Véhicules autonomes

Les 4 principes du NIST pour une IA explicable

1. Explication (Explanation)

- Le système doit fournir des preuves ou des raisons pour chaque résultat
- Accompagner chaque décision d'éléments justificatifs

2. Signification (Meaningful)

- L'explication doit être compréhensible par l'utilisateur visé
- Adapter le niveau de détail au public cible

3. Précision de l'explication (Explanation Accuracy)

- L'explication doit refléter fidèlement le processus réel du modèle
- Pas de contradictions entre explication et comportement

4. Limites de connaissances (Knowledge Limits)

- Le système doit identifier les conditions pour lesquelles il n'est pas fiable
- Indiquer quand la prédiction est incertaine ou hors domaine

Source : NIST, 2021 (9)

1. Évaluation par des experts humains

- Gold standard pour la validation clinique
- Accord inter-annotateurs (ex : dermatologues)
- Permet de détecter les biais et artefacts

2. Métriques informatiques

- **Fidélité (Fidelity)** : L'explication correspond-elle au vrai comportement ?
- **Robustesse (Robustness)** : L'explication est-elle stable face à de petites perturbations ?
- **Complétude (Completeness)** : L'explication couvre-t-elle tous les aspects importants ?

3. Compromis nécessaires

- Une explication fidèle n'est pas toujours compréhensible
- Une explication simple peut être trompeuse

Étude : Explainability agreement between dermatologists and five visual explanations techniques

Source (10)

Protocole :

- Comparaison diagnostic dermatologues vs 5 techniques XAI visuelles
- Images de lésions cutanées (mélanome vs bénin)
- Mesure de l'accord entre experts humains et explications IA

Résultat clé :

- **Grad-CAM : meilleur taux d'accord total/partiel**
- 93,6% d'accord avec les dermatologues
- Les cartes de chaleur correspondent aux zones d'intérêt clinique

Leçon : L'évaluation humaine est essentielle pour valider que l'IA se concentre sur les bons critères cliniques (asymétrie, bords irréguliers, couleur, diamètre, évolution).

1. Secteur Financier (BIS)

- L'explicabilité est une composante de la gestion du risque de modèle (MRM)
- Banques et assurances : obligation de justifier les décisions de crédit
- Auditabilité des modèles par les régulateurs (11)

2. RGPD (Règlement Général sur la Protection des Données)

- Articles 13, 14, 15, 22 : droit à l'information et à l'explication
- Droit de l'individu à obtenir une intervention humaine
- Droit de contester une décision automatisée

3. Standardisation nécessaire

- Besoin de métriques standardisées pour comparer les méthodes
- Fidélité, robustesse, stabilité, complétude

« The Mythos of Model Interpretability »

Zachary C. Lipton, 2018 (4)

Mythe 1 « Les modèles simples sont toujours plus interprétables »

- Faux si le nombre de variables est trop grand pour l'esprit humain
- Une régression linéaire avec 1000 features n'est pas interprétable

Mythe 2 « L'interprétabilité est un concept monolithique »

- Différentes notions : simulatabilité, décomposabilité, transparence algorithmique
- Ce qui est interprétable pour un expert ne l'est pas pour un profane

Mythe 3 « Les explications post-hoc sont toujours fidèles »

- Risque de « fairwashing » : explications plaisantes mais trompeuses
- Une explication peut être cohérente sans être vraie

Le compromis fondamental (Trade-off)

Performance vs Interprétabilité

Modèles interprétables

- Arbres, régressions, règles
- Performance souvent limitée
- Adaptés aux données tabulaires simples

Modèles performants

- Deep Learning, ensembles
- État de l'art sur données complexes
- Difficulté d'explication

Autres défis :

- Risque de manipulation et de « fairwashing »
- Absence de standardisation des métriques d'évaluation
- Coût computationnel des méthodes post-hoc
- Expliquer des modèles de plus en plus grands (LLMs)

Vers une interprétabilité mécaniste (Mechanistic Interpretability)

Une nouvelle frontière

Source : Wikipedia ([12](#))

Principe : Rétro-ingénierie des réseaux de neurones pour comprendre leurs circuits internes.

Objectifs :

- Identifier les neurones et circuits spécialisés
- Comprendre la formation des représentations internes
- Détecter les comportements émergents

Applications prometteuses :

- Interprétabilité des LLM (GPT, LLaMA)
- Détection de biais au niveau neuronal
- Contrôle et alignement des modèles

1. L'interprétabilité n'est pas un concept monolithique

- Elle dépend de l'audience, du contexte et des objectifs
- Un médecin, un juriste et un ingénieur n'ont pas les mêmes besoins

2. Des méthodes variées avec des compromis

- SHAP (théorique mais lent) vs LIME (rapide mais instable)
- Post-hoc (applicable partout) vs intrinsèque (plus fidèle)

3. Un enjeu éthique et réglementaire majeur

- RGPD, gestion du risque de modèle, non-discrimination
- L'explicabilité comme condition de confiance

4. Des perspectives de recherche actives

- Interprétabilité mécaniste, automatisation, standardisation
- Collaboration multidisciplinaire (IA, droit, psychologie, éthique)

- [1] Adadi, A., & Berrada, M. (2020). *Explainable AI : A Survey of Needs, Techniques, Applications, and Future Direction*.
- [2] Barredo Arrieta, A. et al. (2020). *Explainable Artificial Intelligence (XAI) : Concepts, taxonomies, opportunities and challenges*.
- [3] XCALLY (2023). *Interpretability vs explainability : understanding the differences and importance*.
- [4] Lipton, Z. C. (2018). *The Mythos of Model Interpretability*. Communications of the ACM.
- [5] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You ?" : *Explaining the Predictions of Any Classifier*.
- [6] Lundberg, S. M., & Lee, S. I. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS.
- [7] *A Comparative Survey of SHAP and LIME* (2021).
- [8] Selvaraju, R. R. et al. (2017). *Grad-CAM : Visual Explanations from Deep Networks via Gradient-Based Localization*. ICCV.
- [9] NIST (2021). *Four Principles of Explainable Artificial Intelligence*. NIST IR 8312.
- [10] *Explainability agreement between dermatologists and five visual explanations techniques* (2021).
- [11] BIS (2022). *Managing explanations : how regulators can address AI explainability*. Bank for International Settlements.
- [12] Wikipedia (2024). *Mechanistic interpretability*.

Merci pour votre attention !

Résumé des points clés :

- Interprétabilité = comprendre le *comment* (experts)
- Explicabilité = communiquer le *pourquoi* (utilisateurs)
- SHAP (théorique, lent) vs LIME (rapide, instable)
- Grad-CAM : 93,6% d'accord avec dermatologues
- Enjeux RGPD, éthiques, et compromis performance/interprétabilité

Des questions ?