

Soft-CAM : Rendre les modèles boîtes noires auto-explicables pour les décisions à enjeux élevés

Making black box models self-explainable for high-stakes decisions

Cabrel FOSSO

25 avril 2026



Plan de la présentation

- 1 Introduction et Motivation
- 2 Contexte : Les méthodes CAM
- 3 Méthode : SoftCAM
- 4 Protocole Expérimental
- 5 Résultats
- 6 Discussion et Conclusion
- 7 Perspectives : SoftCAM et séries temporelles

Les CNN en médecine : performances vs opacité

Le paradoxe de la performance

Les réseaux de neurones convolutifs (CNN) surpassent souvent les experts humains en imagerie médicale, mais leur opacité freine leur adoption dans les contextes critiques.

Pourquoi l'explicabilité est-elle cruciale ?

1. **Confiance clinique** : les médecins ont besoin de comprendre *pourquoi* un diagnostic est posé
2. **Conformité réglementaire** : le Règlement européen sur l'IA (AI Act) exige l'explicabilité pour les systèmes à haut risque
3. **Détection des biais** : une explication permet de repérer des corrélations fallacieuses apprises par le modèle

Domaines visés par l'article

Ophtalmologie (rétine), Imagerie OCT, Radiologie thoracique (CXR)

Les limites des méthodes post-hoc actuelles

Approche standard

Post-hoc : on entraîne un CNN performant (boîte noire), puis on applique une méthode séparée pour l'expliquer après coup.

- GradCAM, Guided BP
- Integrated Gradients
- ScoreCAM, LayerCAM

Problèmes identifiés

- **Infidélité** : l'explication n'approche qu'approximativement le vrai raisonnement
- **Instabilité** : résultats sensibles aux perturbations
- **Incohérence** : explications contradictoires selon la méthode
- **Surcoût** : passe(s) forward/backward supplémentaire(s)

Une explication post-hoc approxime le modèle, elle ne le reflète pas fidèlement.

Djoumessi & Berens, 2025 (1)

Idée centrale

Modifier l'architecture CNN elle-même pour qu'elle génère ses propres explications en un seul passage forward, sans aucun post-traitement.

Contributions clés :

1. Introduction de **SoftCAM** — modification simple et générale transformant tout CNN boîte noire en modèle auto-explicable
2. Démonstration que la performance de classification est **préservée** sur trois datasets médicaux
3. Régularisation **ElasticNet** directement appliquée aux cartes d'évidence pour améliorer la qualité des explications
4. Évaluation contre **5 méthodes post-hoc** de référence sur plusieurs métriques d'explicabilité

Class Activation Maps (CAM)

Principe fondateur

Zhou et al. (2016) (2) — Combiner linéairement les cartes d'activation de la dernière couche convolutive avec les poids de la couche fully connected.

Formulation :

$$S_{CAM}^c(x_1, x_2) = \sum_{k=1}^D w_k^c A_k(x_1, x_2)$$

- $A_k(x_1, x_2)$: activation du neurone k à la position (x_1, x_2)
- w_k^c : poids d'importance associé à la classe c dans la couche FC
- Nécessite un GAP (Global Average Pooling) avant la couche FC

Limitation

CAM est restreinte aux architectures avec GAP + une seule couche FC. GradCAM étend ce principe à d'autres architectures via les gradients.

GradCAM (3) généralise CAM en calculant les poids d'importance via les gradients :

$$S_{\text{Grad-CAM}}^c(x_1, x_2) = \text{ReLU}\left(\sum_{k=1}^D w_k^c A_k(x_1, x_2)\right)$$

$$\text{avec } w_k^c = \frac{1}{N \times M} \sum_i \sum_j \frac{\partial y^c}{\partial A_k(i, j)}$$

Variantes notables :

- **Basées sur les gradients** : SmoothGrad, GradCAM++, Guided BP, Integrated Gradients
- **Sans gradient** : ScoreCAM, LayerCAM, OptiCAM

*Toutes ces méthodes restent **post-hoc** : elles expliquent un modèle entraîné, sans faire partie de sa prise de décision.*

Vue d'ensemble de l'architecture SoftCAM

Transformation clé : remplacer le GAP + FCL par une couche convolutive 1×1

Architecture CNN standard

- 1 CNN Backbone $g_\phi \rightarrow$ Feature map $\mathbf{Z} \in \mathbb{R}^{N \times M \times D}$
- 2 Global Average Pooling $\rightarrow$ vecteur $1 \times D$
- 3 Fully Connected Layer $\rightarrow$ prédiction $\hat{y}$

Perd l'information spatiale !

Architecture SoftCAM

- 1 CNN Backbone $g_\phi \rightarrow$ Feature map $\mathbf{Z} \in \mathbb{R}^{N \times M \times D}$
- 2 Conv2D $C \times 1 \times 1 \rightarrow$ Cartes d'évidence $\mathbf{A} \in \mathbb{R}^{N \times M \times C}$
- 3 AvgPool + Softmax $\rightarrow$ prédiction $\hat{y}$

Préserve l'information spatiale !

Équivalence FCL $\leftrightarrow$ Conv 1×1

Toute couche fully connected de taille $b_1 \times b_2$ peut être exprimée comme une convolution 1×1 avec b_1 canaux d'entrée et b_2 canaux de sortie — sans perte de capacité.

Cartes d'évidence et prédiction

Le module classificateur **SoftCAM** produit :

$$\mathbf{A} = h_{\psi}(\mathbf{Z}) \in \mathbb{R}^{M \times N \times C}$$

- h_{ψ} : C noyaux convolutifs 1×1 à pas unitaire
- C : nombre de classes
- Chaque canal de $\mathbf{A}$ est une **carte d'évidence de classe** (S_{Map}^c)

La **prédiction finale** :

$$\hat{\mathbf{y}} = \text{Softmax}\left(\text{AvgPool}(h_{\psi}(g_{\phi}(\mathbf{X})))\right) \in \mathbb{R}^{1 \times C}$$

Propriétés clés

- Explication et prédiction en **un seul passage**
- Les poids d'importance sont **appris implicitement**
- Aucun paramètre supplémentaire par rapport au CNN original

Lien avec CAM/GradCAM

h_{ψ} peut être vue comme une généralisation *soft* des méthodes d'attribution post-hoc : elle mappe $\mathbf{Z}$ en un volume d'activation $\mathbf{A}$ directement interprétable.

Régularisation ElasticNet pour l'interprétabilité

Les cartes d'évidence **A** étant directement utilisées pour la classification, on peut y appliquer une régularisation pour améliorer la qualité visuelle des explications.

Fonction de perte SoftCAM :

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = \text{CE}(\mathbf{y}, \hat{\mathbf{y}}) + \lambda_1 \sum_{i,j,c} |\mathbf{A}_c^{ij}| + \lambda_2 \sum_{i,j,c} \|\mathbf{A}_c^{ij}\|_2$$

Régularisation Lasso ($\lambda_2 = 0$)

- Favorise la **parcimonie** : met les activations non informatives à zéro
- Explications **précises** et focalisées
- Idéal quand les lésions sont petites (ex : OCT)

Régularisation Ridge ($\lambda_1 = 0$)

- Réduit les activations sans les annuler
- Explications plus **denses et complètes**
- Idéal pour les grandes régions (ex : pneumonie sur CXR)

ElasticNet = Lasso + Ridge : équilibre entre parcimonie et sensibilité.

Trois datasets d'imagerie médicale couvrant des modalités distinctes :

1. Kaggle Diabetic Retinopathy (DR) — Fonds d'œil couleur

- Score DR de 0 (aucun) à 4 (prolifératif)
- Tâches : classification binaire $\{0\}$ vs $\{1-4\}$ et multi-classe
- Annotations de lésions disponibles pour 65 images (DR dataset (10))

2. Retinal OCT — Tomographie par cohérence optique

- 4 classes : Drusen, Œdème maculaire diabétique, Néovascularisation choroïdale, Normal
- Tâches : binaire (Normal vs Drusen) et multi-classe (4 classes)
- Annotations de lésions pour 40 images Drusen (11)

3. RSNA Chest X-Ray (CXR) — Radiographie thoracique

- Détection de pneumonie (binaire)
- Boîtes englobantes disponibles pour les régions de pneumonie
- Images haute résolution frontales (12)

Modèles de base et méthodes comparées

Architectures CNN

- **ResNet-50** (8) : une seule couche FC — remplacée par Conv 1×1
- **VGG-16** (9) : plusieurs couches FC — toutes remplacées
- Pré-entraînés sur ImageNet, fine-tunés sur chaque dataset
- Entraînement : 70 époques, batch 16, GPU NVIDIA A40

Méthodes post-hoc comparées

- **Basées sur les gradients :**
 - GradCAM (3)
 - Integrated Gradients (4)
 - Guided Backpropagation (5)
- **Sans gradient :**
 - ScoreCAM (6)
 - LayerCAM (7)

Variantes SoftCAM

- **Dense SoftCAM** : $\lambda_1 = \lambda_2 = 0$
- **Sparse SoftCAM** : $\lambda_2 = 0, \lambda_1 > 0$ (Lasso)
- **Ridge SoftCAM** : $\lambda_1 = 0, \lambda_2 > 0$ (Ridge)

Performance de classification :

- **Accuracy** et **AUC** (tâches binaires)
- **Kappa de Cohen quadratique** κ (tâches multi-classes)

Qualité des explications :

Métrique	Description
Top- k Localization Precision	Proportion de patches top- k chevauchant les annotations ground truth
Activation Precision	Proportion d'explications positives dans la boîte englobante
Activation Sensitivity	Pénalise les faux négatifs (lésions manquées)
Faithfulness (Sensitivity)	Chute de confiance lors de la suppression des régions les plus activées

5.1 — La performance de classification est préservée

Table – Performance sur les ensembles de test (Acc. = Accuracy)

Modèle	Kaggle Fundus				OCT retinal		RSNA CXR	
	Binary		Multi-class		Binary		Binary	
	Acc.	AUC	Acc.	κ	Acc.	AUC	Acc.	AUC
VGG-16 (original)	0.907	0.938	0.863	0.835	0.994	1.0	0.952	0.989
Dense VGG*	0.915	0.942	0.861	0.834	0.994	1.0	0.957	0.999
Sparse VGG*	0.911	0.938	0.859	0.827	0.988	0.999	0.953	0.990
ResNet-50 (original)	0.899	0.923	0.850	0.800	0.994	0.999	0.953	0.988
Dense ResNet*	0.899	0.923	0.851	0.811	0.994	1.0	0.942	0.983
Sparse ResNet*	0.895	0.923	0.851	0.801	0.996	1.0	0.941	0.979

Observation clé

Les variantes SoftCAM (*) maintiennent des performances **comparables ou légèrement supérieures** à leurs homologues boîtes noires — la modification architecturale est sans coût de performance.

5.2 — Des explications visuelles intrinsèquement interprétables

Comparaison qualitative des cartes de saillance (ResNet-50) :

Observations

- SoftCAM produit des cartes avec des **régions de haute activation concentrées sur les lésions annotées**
- Le Sparse SoftCAM est un sous-ensemble du Dense SoftCAM (effet du Lasso)
- Sur images saines : les cartes sparses montrent davantage d'activations négatives

Cohérence d'activation

Dense vs Sparse SoftCAM (ResNet, Fundus) :

- Dense : 0.55 d'activations positives sur images malades
- Sparse : 0.27 d'activations positives sur images saines

⇒ Contraste net maladie/santé

Avantage fondamental

Contrairement aux méthodes post-hoc, les cartes SoftCAM **constituent directement la base de la décision** du modèle — elles ne sont pas une

5.3 — Localisation et fidélité des explications

Top- k Localization Precision (proportion de patches top- k chevauchant les annotations) :

- **Sparse ResNet*** obtient la **meilleure précision top- k** sur Fundus et OCT parmi toutes les méthodes
- SoftCAM souligne **moins de régions, mais plus pertinentes** — les méthodes post-hoc génèrent davantage de faux positifs

Faithfulness (Sensitivity Analysis) — suppression progressive des patches les plus activés :

OCT & RSNA CXR

Sparse SoftCAM **surpasse toutes les méthodes post-hoc** en fidélité — les régions supprimées impactent davantage la confiance du modèle.

Fundus

SoftCAM se situe légèrement sous Guided BP et Integrated Gradients — ces méthodes bénéficient de cartes haute résolution pixel par pixel.

5.4 — La régularisation Ridge pour les grandes régions

Contexte : RSNA CXR

La pneumonie se manifeste sur de larges zones thoraciques (pas des lésions ponctuelles). La régularisation Lasso est trop restrictive dans ce cas — elle manque des régions pertinentes.

Résultats comparatifs sous performance similaire ($\text{Acc.} \approx 0.95$) :

- **Sparse SoftCAM** : meilleure **Activation Precision** (évite les faux positifs)
- **Ridge SoftCAM** : meilleure **Activation Sensitivity** (évite de manquer des lésions)
- **Dense SoftCAM** : performance intermédiaire équilibrée

Conclusion pratique

Le choix du régularisateur doit être guidé par la nature des lésions :

- Lasso → lésions petites et ponctuelles (précision)
- Ridge → grandes régions pathologiques (sensibilité/rappel)
- ElasticNet → compromis adaptatif

5.5 — Explications multi-classes et efficacité

Extension aux tâches multi-classes (DR grading, OCT 4 classes) :

1. **Performance maintenue** : Kappa comparable aux CNN boîtes noires (légère amélioration sur Fundus avec ResNet)
2. **Explications classe-spécifiques** : une carte d'évidence par classe — générées **en un seul passage forward**
3. **Cohérence biologique** : pour la DR progressive, les images de grade x (avec $1 < x < 5$) présentent des activations pour les grades antérieurs — cohérent avec la nature cumulative de la maladie

Avantage computationnel

Les méthodes post-hoc nécessitent C passes (une par classe) pour les explications multi-classes. SoftCAM produit les C cartes **simultanément** en une seule inférence.

Faithfulness multi-classe

Dense et Sparse SoftCAM obtiennent les **meilleures courbes de suppression** (aire sous la courbe de suppression minimale = fidélité maximale).

Forces de SoftCAM

- **Auto-explicable par design** : pas de post-traitement
- **Universellement applicable** : tout CNN boîte noire
- **Pas de paramètres supplémentaires** par rapport au modèle original
- **Régularisation directe** sur les cartes d'explication
- **Efficacité** : C explications en un seul forward pass

Limites identifiées

- Résolution des cartes limitée par le backbone (ex : 16×16 pour VGG-16/ResNet-50 avec entrée 512×512)
- Méthodes pixel par pixel (Guided BP, IG) produisent des cartes plus fines sur certains datasets
- Non évalué sur architectures Vision Transformer (ViT)
- Sélection du paramètre λ requiert une validation sur ensemble de validation

« SoftCAM démontre que le compromis performance/interprétabilité peut être résolu sans coût majeur, ouvrant la voie à une IA clinique plus fiable. »

1. Un CNN peut être intrinsèquement interprétable

- Remplacer GAP + FCL par Conv 1×1 suffit pour que le modèle génère ses propres explications
- Pas de dégradation de performance sur trois datasets médicaux

2. La régularisation ElasticNet améliore les explications sans nuire à la classification

- Lasso $\rightarrow$ parcimonie (lésions focales), Ridge $\rightarrow$ complétude (grandes régions)

3. SoftCAM surpasse les méthodes post-hoc en explicabilité quantitative

- Meilleure fidélité sur OCT et CXR, précision compétitive sur Fundus

4. Perspectives ouvertes

- Intégration avec les Vision Transformers (ViT)
- Évaluation clinique par des médecins (accord inter-annotateurs)
- Extension à d'autres modalités (IRM, PET-scan)

Question ouverte : SoftCAM et Transformers

Rappel : l'idée centrale de SoftCAM

Remplacer la tête de classification (GAP + FCL) par une couche qui préserve la dimension spatiale, de sorte que les cartes d'évidence **constituent directement** la décision du modèle.

Question

Est-il possible d'appliquer une stratégie similaire à une architecture Transformer, de façon à ce que le modèle soit **intrinsèquement auto-explicable** — sans post-traitement ?

Les tokens de sortie du Transformer portent-ils une information suffisamment localisée pour jouer le rôle des cartes d'évidence de SoftCAM ?

Explicabilité des Transformers sur séries temporelles : méthodes

1. Attention Maps brutes

- Visualiser quels pas de temps s'influencent mutuellement
- **Limite** : les poids d'attention ne sont pas directement des importances

2. Attention Rollout (Abnar & Zuidema, 2020)

- Propager l'attention à travers toutes les couches pour un score global par pas de temps
- Sans backpropagation — facile à mettre en œuvre

3. Integrated Gradients (4)

- Contribution de chaque pas de temps à la prédiction finale
- Méthode de référence, applicable à tout modèle différentiable

4. TimeSHAP (Bento et al., KDD 2021)

- Valeurs de Shapley par **pas de temps** et par **variable**
- **Solution la plus complète** pour les séries multivariées

Recommandation pratique

Commencer par **Attention Rollout** (aucune modification du modèle), puis **TimeSHAP** pour une analyse rigoureuse par variable et par pas de temps.

- [1] Djoumessi, K., & Berens, P. (2025). *Soft-CAM : Making black box models self-explainable for high-stakes decisions*. Preprint arXiv :2505.17748.
- [2] Zhou, B. et al. (2016). *Learning deep features for discriminative localization*. CVPR.
- [3] Selvaraju, R. R. et al. (2017). *Grad-CAM : Visual Explanations from Deep Networks via Gradient-Based Localization*. ICCV.
- [4] Sundararajan, M. et al. (2017). *Axiomatic Attribution for Deep Networks*. ICML.
- [5] Springenberg, J. T. et al. (2014). *Striving for Simplicity : The All Convolutional Net*. arXiv.
- [6] Wang, H. et al. (2020). *Score-CAM : Score-Weighted Visual Explanations for CNNs*. CVPR Workshops.
- [7] Jiang, P.-T. et al. (2021). *LayerCAM : Exploring Hierarchical Class Activation Maps for Localization*. IEEE TIP.
- [8] He, K. et al. (2016). *Deep Residual Learning for Image Recognition*. CVPR.
- [9] Simonyan, K., & Zisserman, A. (2015). *Very Deep Convolutional Networks for Large-Scale Image Recognition*. ICLR.
- [10] Kaggle (2019). *APTOS 2019 Blindness Detection*. Kaggle Competition.
- [11] Kermany, D. et al. (2018). *Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning*. Cell.
- [12] Shih, G. et al. (2019). *Augmenting the National Institutes of Health Chest Radiograph Dataset with Expert Annotations*. Radiology : AI.
- [13] Abnar, S., & Zuidema, W. (2020). *Quantifying Attention Flow in Transformers*. ACL.
- [14] Bento, J. et al. (2021). *TimeSHAP : Explaining Recurrent Models through Sequence Perturbations*. KDD.

Merci pour votre attention !

Résumé des points clés :

- SoftCAM = remplacer GAP + FCL par Conv $1 \times 1 \rightarrow$ auto-explicabilité intrinsèque
- Performance préservée sur 3 datasets médicaux (DR, OCT, CXR)
- ElasticNet sur les cartes d'évidence : Lasso (précision) vs Ridge (sensibilité)
- Surpasse les méthodes post-hoc en fidélité sur OCT et CXR
- Explications multi-classes en un seul forward pass

Des questions ?