

Méthodes d'Explicabilité en IA

De LIME à SoftCAM — Panorama et application à la prédiction de charge
FaaS

FOSSO Cabrel

Université de Dschang

28 avril 2026

Plan de la présentation

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

L'explicabilité : pourquoi maintenant ?

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

Le paradoxe performances / confiance

- Les modèles ML modernes atteignent des performances remarquables : ResNet, GPT, Transformers ...
- Mais leur complexité les rend **opaques** :
 - Millions de paramètres
 - Décisions non traçables
 - Comportements inattendus hors distribution
- Résultat : **les utilisateurs ne font pas confiance** aux prédictions qu'ils ne comprennent pas

Dilemme

Performance élevée

vs

Confiance & déployabilité

Constat

Un modèle précis
mais inexplicable
ne peut pas être déployé
dans un secteur critique

Enjeux concrets : réglementation et secteurs critiques

Réglementation

- **EU AI Act (2024)** : exige la traçabilité des décisions automatisées dans les systèmes à risque élevé
- **RGPD** : droit à l'explication pour les décisions automatisées

Santé	Finance	Cloud / FaaS
Diagnostic, imagerie médicale : le médecin doit comprendre la prédiction	Décision de crédit, détection de fraude : obligation légale d'explication	Allocation de ressources : les opérateurs ont besoin de comprendre les pics de charge

EU AI Act, 2024 ; RGPD Art. 22

Qu'est-ce qu'une bonne explication ?

3 dimensions clés

- **Portée**

- **Locale** : expliquer *une* prédiction
- **Globale** : expliquer le comportement général du modèle

- **Fidélité**

L'explication reflète-t-elle vraiment le raisonnement du modèle ?

- **Interprétabilité**

L'explication est-elle compréhensible par un humain non expert ?

3 propriétés souhaitables (SHAP)

- **Précision locale** : l'explication prédit correctement localement
- **Missingness** : une feature absente a contribution nulle
- **Cohérence** : si une feature contribue plus dans un modèle, son score ne doit pas diminuer

Contexte : les travaux de FAYAM

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

Prédiction de charge FaaS : le problème métier

- **FaaS** (Function-as-a-Service) :
paradigme cloud où les fonctions s'exécutent à la demande
- **Défi** : les invocations sont imprévisibles
— pics de charge soudains, saisonnalités complexes
- **Enjeu** : pré-allouer les ressources pour éviter la latence ou le gaspillage
- **Solution** : prédire le nombre d'invocations futures à partir de l'historique

Dataset FAYAM

- 18 fonctions FaaS instrumentées
- Séries temporelles multivariées
- 33 clusters de profils de charge (DBSCAN — k-distance)
- Horizon de prédiction :
predictionLength

Les deux architectures proposées par FAYAM

Modèle 1 — CNN-LSTM

- Extraction de features locales (CNN)
- Mémorisation séquentielle (LSTM)
- Approche hybride

(Mentionné pour exhaustivité — hors de notre périmètre)

Modèle 2 — Transformer **[focus]**

- TimeSeriesTransformer HuggingFace
- Encodeur-Décodeur
- Mécanisme d'attention multi-têtes
- `output_attentions=True`

C'est ce modèle que nous allons chercher à expliquer

Résultats du Transformer sur les datasets de test

Métriques de performance (phase test — FAYAM, 2024)


Modèle	sMAPE	RMSE	R ²	Spearman
CNN-LSTM	(valeur)	(valeur)	(valeur)	(valeur)
Transformer	(valeur)	(valeur)	(valeur)	(valeur)

Note : à compléter après reproduction des expériences FAYAM (Phase 1 du projet)

Interprétation

- Les performances sont **compétitives** par rapport à l'état de l'art FaaS
- Le Transformer surpasse le CNN-LSTM sur la majorité des datasets

Le verrou : de bonnes performances, mais aucune explication



Conséquence directe

Un opérateur FaaS ne peut pas **valider**, **auditer** ni **faire confiance** à un modèle qui ne justifie pas ses prédictions.

La déployabilité dans un secteur critique : impossible

Taxonomie des méthodes d'explicabilité

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité**
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

Axes de classification

Axe 1 — Quand ?

- **Post-hoc** : (*LIME, SHAP, TimeSHAP*)
- **Ante-hoc** : (*arbres décision, régression log.*)
- **Pendant l'entraînement** : (*SoftCAM* ← *focus*)

Axe 2 — Qui ?

- **Agnostique** : (*LIME, SHAP*)
- **Spécifique** : (*CAM, GradCAM, SoftCAM*)

Axe 3 — Quelle portée ?

- **Locale**
- **Globale**
- **Semi-locale** : (*TsSHAP*)

Axe 4 — Quelle tâche ?

- **Classification**
- **Régression**
- **Prévision** : ← *notre cas FaaS*

Positionnement de toutes les méthodes

Comparaison des méthodes d'explicabilité

Méthode	Quand ?	Agnostic ?	Prévision ?	Transformer ?	Famille
LIME	Post-hoc	✓	×	✓	Perturbation
KernelSHAP	Post-hoc	✓	×	✓	SHAP
TimeSHAP	Post-hoc	✓	×	partiel	SHAP
WindowSHAP	Post-hoc	✓	×	partiel	SHAP
TsSHAP	Post-hoc	✓	✓	✓	SHAP
SHAPformer	Post-hoc	partiel	✓	✓	SHAP
CAM	Post-hoc	×	×	×	CAM
GradCAM	Post-hoc	×	×	×	CAM
SoftCAM	Entraîn.	×	✓*	✓*	CAM

* Extension proposée dans notre projet (H1) : transposition du principe SoftCAM au Transformer de FAYAM

Notre positionnement

Aucune méthode existante ne couvre parfaitement notre cas — **c'est précisément notre contribution**

Famille SHAP : des perturbations locales aux valeurs exactes

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

LIME — Ribeiro, Singh & Guestrin (KDD 2016)

Problème résolu

Comment expliquer la prédiction d'un modèle quelconque de façon **localement fidèle** et **interprétable** ?

Méthode

Apprendre un modèle linéaire sparse g autour de x :

$$\xi(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

- $\pi_x(z) = \exp(-D(x, z)^2 / \sigma^2)$: noyau de proximité
- $\Omega(g)$: complexité (nb de features non nulles)

Représentations interprétables

- Texte : présence ou absence de mots
- Image : super-pixels (patches)
- Tabulaire : présence ou absence de features

Algorithme (K-Lasso)

- 1 Échantillonner N instances autour de x
- 2 Pondérer par π_x
- 3 Lasso $\rightarrow$ garder K features
- 4 OLS $\rightarrow$ poids finaux

LIME — Résultats et SP-LIME

Résultats (fidélité)

Recall sur features importantes :

- **LIME** : $> 90\%$ sur tous les classifieurs (books + DVDs)
- Greedy : 64% (books) — 33% (DVDs)
- Random : $\sim 17\%$

F1 trustworthiness LIME : **96,6 / 94,5 / 96,2 / 96,7**
(LR / NN / RF / SVM sur Books)

SP-LIME — confiance globale

Sélectionner B instances représentatives et **non-redondantes** par optimisation sous-modulaire greedy

Limite clé

- **Instabilité** : deux runs = deux explications différentes
- **Fidélité locale $\neq$ fidélité globale**
- Pas de garanties théoriques sur cohérence et missingness
- **Pas adapté aux séries temporelles** : features traitées comme indépendantes

Exemple célèbre

Husky vs Wolf : LIME révèle que le classifieur utilise la **neige en arrière-plan**, pas l'animal

LIME — Ce que cela nous enseigne

Apports fondamentaux

- Premier cadre **model-agnostique** rigoureux pour l'XAI post-hoc
- Notion de **représentation interprétable**
- SP-LIME : pont vers la confiance globale

Ce qui manque

- Garanties théoriques solides
- Stabilité des explications
- Adaptation au domaine temporel

Un an plus tard (2017), Lundberg & Lee unifieront LIME et d'autres méthodes sous un cadre théorique unique basé sur la **théorie des jeux coopératifs**

La naissance de **SHAP** — **Shapley Additive Explanations**

KernelSHAP — Lundberg & Lee (NeurIPS 2017)

La valeur de Shapley

Issue de la théorie des jeux coopératifs (Shapley, 1953). Contribution **juste et unique** de chaque feature i :

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

⇒ contribution marginale moyennée sur toutes les coalitions

KernelSHAP

Reformule le calcul des valeurs de Shapley comme une régression pondérée (LASSO) — approximation de LIME avec le **bon noyau**

SHAP unifie LIME, DeepLIFT, SHAP linéaire. . .

Seule solution satisfaisant **simultanément** :

- 1 **Précision locale**
- 2 **Missingness**
- 3 **Cohérence**

Limite


Calcul exact : $2^{|F|}$ coalitions. KernelSHAP **approxime** par échantillonnage. Coût élevé pour longues séquences.

KernelSHAP face aux séquences temporelles

Le problème central

KernelSHAP attribue de l'importance aux features du **pas de temps courant uniquement**.

Il ignore l'historique de la séquence et l'état caché du modèle récurrent.



⇒ Il faut adapter SHAP au domaine séquentiel : **TimeSHAP**

Pause — Pourquoi SHAP s'impose face à LIME

LIME

- ✓ Précision locale
- × Missingness (non garantie)
- × Cohérence (non garantie)
- × Instabilité due au sampling
- × Pas de fondement axiomatique

SHAP (KernelSHAP)

- ✓ Précision locale
- ✓ Missingness
- ✓ Cohérence
- ✓ Solution **unique** par les axiomes de Shapley
- ✓ TreeSHAP exact en temps polynomial

Conclusion de cette pause

La famille SHAP est le **standard théorique** pour l'XAI post-hoc.
Les prochaines méthodes sont toutes des **extensions SHAP**
adaptées aux séries temporelles.

Problème résolu

SHAP ignore l'historique des RNN. TimeSHAP étend KernelSHAP au domaine séquentiel avec des **perturbations bidimensionnelles**.

Méthode

Matrice $X \in \mathbb{R}^{d \times l}$ (d features, l événements)

- **Features** : $h_X^f(z) = D_z X + (I - D_z) B$
- **Événements** : $h_X^e(z) = X D_z + B(I - D_z)$
- **Cellules** : intersection features $\times$ événements

Élagage temporel

$O(2^l) \rightarrow O(l \cdot 2^{l-i})$ Médiane : 138,5 $\rightarrow$ **14,0** événements ($\eta = 0,025$)

Résultats (fraude bancaire)

- GRU + feed-forward, $\sim 20\text{M}$ instances
- Recall 84,3% @ 1% FPR
- Événement $t = 0$: **41%** du score
- Pattern : enrollment-login-transaction
- Biais détecté : âge $\leftrightarrow$ taux FP

Limite

Conçu pour la **classification**.

Pas adapté à la prévision (FAYAM).

TimeSHAP — Élagage temporel et explications cellules

Algorithme d'élagage (Alg. 1)

- 1 Parcourir la séquence de la fin vers le début
- 2 Si $|w_1| < \eta$: grouper les événements passés
- 3 Complexité finale : $O(l \cdot 2^{l-i})$

Pruning Table (Table 1)

	Original	$\eta = 0,025$
Longueur médiane	138,5	14,0
RSD	1,71	0,98

3 niveaux d'explication

- **Événements** : quels instants ?
- **Features** : quelles variables ?
- **Cellules** : quels (feature, instant) ?

Transposabilité à FAYAM

S'applique en boîte noire au Transformer FAYAM, mais explique un score de probabilité — pas une prévision de charge. Adaptation requise.

Bento et al., KDD 2021

WindowSHAP — Nayebi et al. (J. Biomedical Informatics, 2023)

Idée centrale

Réduire le coût de KernelSHAP en calculant des valeurs Shapley par **fenêtre temporelle** plutôt que par pas de temps.

3 variantes

- **Stationary** : fenêtres fixes, non chevauchantes
- **Sliding** : fenêtres chevauchantes (stride s)
- **Dynamic** : longueur variable (divise les fenêtres importantes, agrège les autres)

Résultats clés

- -80% **CPU** vs KernelSHAP (10 pas fusionnés, $L = 120$)
- Dynamic : meilleure qualité car **pas d'hypothèse** sur les instants importants
- 3 datasets cliniques (TBI, MIMIC-III)

Limite

Validé uniquement en **classification**.
Pas de librairie Python officielle.

TsSHAP — Raykar et al. (IBM Research, 2023) [Le plus pertinent]

Problème résolu

Seule méthode SHAP conçue nativement pour la prévision.

LIME, KernelSHAP, TimeSHAP, WindowSHAP expliquent des scores de classification — pas des prévisions.

Pipeline

- 1 **Backtesting** → prévisions historiques $\hat{y}(T + h|T)$
- 2 **Features interprétables** : lags, saisonnalités, date/heure
- 3 **Surrogate XGBoost** : imite le forecaster
- 4 **TreeSHAP** : valeurs Shapley sur le surrogate

TsSHAP — Features interprétables

3 portées d'explication

Locale : une prédiction

Semi-locale : un horizon

Globale : toute la série

Features interprétables (Tables 1-2)

- `LagFeatures` : $y(t - k)$
- `SeasonalLagFeatures` : $y(t - k \cdot m)$
- `RollingWindowFeatures` : max, min, mean
- `DateFeatures` : mois, jour, semaine...
- `HolidayFeatures` : jours fériés

TsSHAP reste la **référence** pour l'explicabilité en prévision, mais nécessite un surrogate XGBoost (fidélité approximative).

TsSHAP — Résultats et limites

Résultats (Fidélité — Table 6)

Fidélité moyenne sur 5 datasets :

- **MovingAverage** : 0,244 (global) / 0,654 (local)
- Explications **semi-locales** toujours plus fidèles
- Complexité stable entre portées

Illustration (jeans-sales-weekly)

- SeasonalNaive $\rightarrow$ sales($t-52$)
- Prophet $\rightarrow$ discount(t) = principale feature externe
- XGBoost $\rightarrow$ sales($t-1$) domine

Limites

- **Univarié uniquement**
FAYAM = 18 fonctions
 $\rightarrow$ à appliquer par série
- **Surrogate $\neq$ modèle réel**
XGBoost peut mal imiter un Transformer
- **Features à définir manuellement**

Pour notre projet

TsSHAP est le **H2 prioritaire** si H1 (SoftCAM-Transformer) échoue

SHAPformer — Hertel et al. (KIT, déc. 2025)

Problème résolu

Calculer des valeurs SHAP **exactes** pour les Transformers de prévision **sans échantillonnage** — en moins d'une seconde.

Mécanisme

- 1 Grouper les features en N groupes
 - 2 Entraîner avec **entrées masquées** (masked attention)
 - 3 Inférence : évaluer sur les 2^N sous-ensembles via attention
- ⇒ SHAP **exact**, pas de Monte Carlo

Résultats (TransnetBW, Table 1)

Méthode	Inférence
Permutation Explainer	484 s
Custom Masker	3,54 s
SHAPformer	0,60 s
800× plus rapide RMSE comparable	

Limite

Réentraînement requis.
Complexité $\propto 2^N$ groupes de features.

Famille CAM : de l'activation à l'évidence

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence**
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

Class Activation Maps

Pour un CNN classifieur :

$$M_c(x, y) = \sum_k w_k^c \cdot f_k(x, y)$$

- f_k : k -ème feature map dernière couche conv.
- w_k^c : poids FC pour la classe c
- M_c : carte de chaleur des régions discriminantes

Contrainte

Requiert un GAP avant la couche FC.
Architecture imposée, pas universelle.

Principe visuel

- Image $\rightarrow$ CNN $\rightarrow$ Feature maps
- GAP $\rightarrow$ FC $\rightarrow$ Classe
- Carte : quelles régions activent la décision ?

Intérêt

Première méthode à **localiser** ce que le modèle regarde, sans back-propagation ni perturbation

GradCAM — Selvaraju et al. (ICCV 2017) : extension gradient

Contribution

Généralise CAM à toute architecture CNN sans contrainte GAP, via les **gradients** du score de classe c :

$$\alpha_k^c = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}$$

$$L_{\text{GradCAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$$

Avantages vs CAM

- Applicable à **toute couche** convolutive
- Pas de contrainte architecturale
- Cartes de résolution variable

Limites persistantes

- Méthode **post-hoc** : un back-pass par classe
- Résolution limitée à la feature map cible
- Sensible aux gradients saturés

SoftCAM — Djoumessi & Berens (arXiv, mai 2025)

Problème fondamental posé par les auteurs

Les méthodes post-hoc (GradCAM, SHAP, IG...) approximent le raisonnement *après coup*. Elles sont **sensibles aux perturbations**, **infidèles** et ne reflètent pas le vrai processus décisionnel.

Architecture	SoftCAM	Propriété	clé
CNN standard : Backbone $\rightarrow$ GAP $\rightarrow$ FCL $\rightarrow$ Softmax			
SoftCAM (modification minimale) : Backbone $\rightarrow$ $\underbrace{\text{Conv}_{1 \times 1}}_{\text{class-evidence layer}} \rightarrow$ AvgPool $\rightarrow$ Softmax		• 1 seul forward pass pour toutes les classes • Explication intrinsèque : la carte est la prédiction • Aucun paramètre supplémentaire vs FCL	
Sortie : $A \in \mathbb{R}^{M \times N \times C}$ — carte d'évidence			

Avant / Après

Post-hoc $\rightarrow$ back-pass ou perturbations

SoftCAM $\rightarrow$ **0 coût supplémentaire**

Djoumessi & Berens, arXiv :2505.17748, mai 2025

SoftCAM — Régularisation ElasticNet

Loss augmentée (Eq. 5)

$$\mathcal{L}(y, \hat{y}) = \underbrace{\text{CE}(y, \hat{y})}_{\text{performance}} + \underbrace{\lambda_1 \sum_{c,i,j} |A_c^{i,j}|}_{\ell_1 \text{ — Lasso}} + \underbrace{\lambda_2 \sum_{c,i,j} \|A_c^{i,j}\|_2^2}_{\ell_2 \text{ — Ridge}}$$

Sparse SoftCAM ($\lambda_1 > 0$)

Lasso → cartes
parcimonieuses

Lésions focales,
régions précises

Dense Soft- CAM ($\lambda_2 > 0$)

Ridge → cartes
lissées

Grandes régions,
faux négatifs
coûteux

ElasticNet ($\lambda_1 + \lambda_2$)

Compromis
adaptatif

Trade-off
contrôlable par λ

Djoumessi & Berens, 2025 — $\lambda_1 \in [10^{-6}, 9 \times 10^{-4}]$, $\lambda_2 \in [7 \times 10^{-5}, 2 \times 10^{-4}]$

SoftCAM — Résultats expérimentaux

Performance préservée (Table 1)

Modèle	Backbone	AUC
Standard	VGG-16	0,938
SoftCAM dense	VGG-16	0,942
SoftCAM sparse	VGG-16	0,938
Standard	ResNet-50	0,999
SoftCAM	ResNet-50	1,000

La modification n'altère pas la précision

Coût computationnel

1 forward pass contre : 1 back-pass (gradient-based) ou N forward passes (perturbation-based)

Explicabilité (Fig. 3)

Sparse SoftCAM ResNet **surpasse toutes les méthodes post-hoc** en top-k precision (fundus + OCT) :
vs GradCAM, IG, Guided Backprop, Score-CAM, LayerCAM

Djoumessi & Berens, 2025 — 3 datasets médicaux : Kaggle DR Fundus, Retinal OCT, RSNA CXR

SoftCAM — Perspective et lien avec notre projet

Limites identifiées

- Résolution coarse (feature maps 16×16)
- Évalué uniquement sur CNN (imagerie médicale 2D)
- Trade-off λ task-specific (à calibrer)

Porte ouverte (p. 10)

"In the future, we could explore the integration of SoftCAM with other standard architectures like ViT."

⇒ **C'est exactement notre H1**

Notre transposition — H1

Adapter SoftCAM au TimeSeriesTransformer de FAYAM :

- Couche cible : **projection finale du décodeur** ($d_{\text{model}} \rightarrow \text{distribution}$)
- Evidence map : $[\text{predictionLength} \times \text{contextLength}]$
- ElasticNet : sparsité temporelle (lags critiques)
- Validation : comparer avec attention maps (H3)

Comparaison synthétique

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique**
- 7 Retour sur FAYAM : quelle voie choisir ?

Tableau comparatif

Méthode	Famille	Paradigme	Agnostic	Prévision	Transformer	Fidélité	Coût inférence
LIME	Perturbation	Post-hoc	✓	×	✓	Faible	N evals
KernelSHAP	SHAP	Post-hoc	✓	×	✓	Bonne	$\sim 2^{ F }$ evals
TimeSHAP	SHAP	Post-hoc	✓	×	partiel	Bonne	$O(l \cdot 2^{l-i})$
WindowSHAP	SHAP	Post-hoc	✓	×	partiel	Bonne	—80% CPU
TsSHAP	SHAP	Post-hoc	✓	✓	✓	Bonne	TreeSHAP rapide
SHAPformer	SHAP	Post-hoc*	partiel	✓	✓	Exacte	< 1 s
CAM	CAM	Post-hoc	×	×	×	Mod.	1 back-pass
GradCAM	CAM	Post-hoc	×	×	×	Mod.	1 back-pass
SoftCAM	CAM	Intrinsèque	×	✓*	✓*	Maximale	1 fwd pass

* Extension proposée dans notre projet (H1)

* SHAPformer requiert réentraînement (pas modification architecturale)

Lecture du tableau — Aucune méthode n'est parfaite pour notre cas

Ce que le tableau révèle

- LIME / KernelSHAP : pas de séries temporelles
- TimeSHAP / WindowSHAP : pas de prévision
- TsSHAP : prévision ✓, mais univarié + surrogate
- SHAPformer : Transformer + prévision ✓, mais réentraînement
- SoftCAM original : CNN uniquement

Ce qui manque dans la littérature

Une méthode **simultanément** :

- ✓ Adaptée aux **Transformers**
- ✓ Conçue pour la **prévision**
- ✓ À **fidélité intrinsèque**
- ✓ Séries **multivariées**
- ✓ Sans surcoût à l'inférence


C'est précisément ce vide que notre H1 cherche à combler

Retour sur FAYAM : quelle voie choisir ?

- 1 L'explicabilité : pourquoi maintenant ?
- 2 Contexte : les travaux de FAYAM
- 3 Taxonomie des méthodes d'explicabilité
- 4 Famille SHAP : des perturbations locales aux valeurs exactes
- 5 Famille CAM : de l'activation à l'évidence
- 6 Comparaison synthétique
- 7 Retour sur FAYAM : quelle voie choisir ?

Architecture TimeSeriesTransformer — La couche cible

Architecture TimeSeriesTransformer HuggingFace



Adaptation SoftCAM (H1)

Remplacer la projection finale par une **couche d'évidence temporelle** produisant un tenseur [predictionLength $\times$ contextLength]

Risque H1

La convolution 1×1 préserve les positions spatiales d'un CNN. Un Transformer mélange les positions par self-attention. L'extension n'est pas triviale.

H1 — SoftCAM-Transformer (prioritaire)

- Modifier la projection finale du décodeur
- Loss = CE + ElasticNet sur la carte d'évidence
- Réentraîner le Transformer avec cette contrainte
- Résultat : carte $[\text{predL} \times \text{ctxL}]$ intrinsèque

Avantage : fidélité maximale, 1 forward pass

Risque : incompatibilité CNN $\rightarrow$ Transformer

H2 — TsSHAP / SHAPformer (repli)

- TsSHAP : surrogate XGBoost sur backtests FAYAM
- SHAPformer : réentraîner avec masked attention

Avantage : sans modifier l'architecture (TsSHAP) ou code public (SHAPformer)

Risque : fidélité moindre (surrogate)

Notre hypothèse prioritaire : H1 — SoftCAM-Transformer

Contribution scientifique visée

**Première transposition documentée d'un schéma SoftCAM-like
à un Transformer de séries temporelles,**
avec étude différentielle par cluster DBSCAN (profils de charge FaaS)

Critère de bascule vers H2

Si après un bon moment :

- L'adaptation SoftCAM ne converge pas, **ou**
- La performance de prédiction dégrade significativement

⇒ **Basculer sur H2 sans attendre**

H3 — Attention weights (validation)

Si H1 ou H2 aboutit, les attention maps extraites par `output_attentions=True` servent à **valider** la cohérence des explications obtenues

Questions ouvertes et prochaines étapes

Questions méthodologiques ouvertes

- 1 Comment définir l'équivalent d'une *class evidence map* pour la **régression** multi-horizons ?
- 2 Quel est l'équivalent temporel des super-pixels CNN ? (patch temporel ? lag ? cluster DBSCAN ?)
- 3 Comment évaluer la fidélité sur une tâche de prévision ? (comprehensiveness / sufficiency adaptés)

Prochaines étapes (Phase 1)

- 1 Récupérer le code FAYAM
- 2 Agréger le dataset + EDA
- 3 Entraîner TimeSeriesTransformer (output_attentions=True)
- 4 Cartographier la projection du décodeur
- 5 Métriques FAYAM (sMAPE, RMSE, R^2 , Spearman)

Merci pour votre attention

Des questions ?

Références I



M.T. Ribeiro, S. Singh, C. Guestrin. *“Why Should I Trust You ?” Explaining the Predictions of Any Classifier*. KDD 2016. arXiv :1602.04938.



S.M. Lundberg, S.-I. Lee. *A Unified Approach to Interpreting Model Predictions*. NeurIPS 2017.



J. Bento, P. Saleiro, A.F. Cruz, M.A.T. Figueiredo, P. Bizarro. *TimeSHAP : Explaining Recurrent Models through Sequence Perturbations*. KDD 2021. arXiv :2012.00073.



A. Nayebi, M. Tipirneni, C. Reddy, F. Foreman, V. Subbian. *WindowSHAP : An Efficient Framework for Explaining Time-Series Classifiers Based on Shapley Values*. Journal of Biomedical Informatics, 2023. DOI :10.1016/j.jbi.2023.104438.



V.C. Raykar, A. Jati, S. Mukherjee, N. Aggarwal, K. Sarpatwar, G. Ganapavarapu, R. Vaculin. *TsSHAP : Robust Model Agnostic Feature-Based Explainability for Time Series Forecasting*. arXiv :2303.12316, IBM Research, 2023.



M. Hertel, S. Pütz, R. Mikut, V. Hagenmeyer, B. Schäfer. *SHAPformer : Explainable Time Series Forecasting with Sampling-Free SHAP Values for Transformers*. arXiv :2512.20514, KIT, décembre 2025.



B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, A. Torralba. *Learning Deep Features for Discriminative Localization*. CVPR 2016.



R.R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra. *Grad-CAM : Visual Explanations from Deep Networks via Gradient-Based Localization*. ICCV 2017.



K. Djoumessi, P. Berens. *SoftCAM : Making Black Box Models Self-Explainable*. arXiv :2505.17748, mai 2025.

Références II



J. Fayam *et al.* *Prédiction de charge FaaS par réseaux de neurones profonds*. Mémoire Master 2, Université de Dschang, 2024.