

Validation H1 : SoftCAM-Transformer

Explication fidèle par construction pour la prédiction de charge FaaS
Présentation des résultats

FOSSO Cabrel

Université de Dschang

20 mai 2026

Plan de la présentation

- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

Contexte, état de l'art et architecture

- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

Le problème métier : prédiction de charge FaaS

- Le **serverless** (FaaS) facture à l'invocation, sans gestion de serveurs.
- Mais le **cold-start** (démarrage à froid des containers) dégrade la latence.
- Solution : **prédire la charge à venir** pour pré-chauffer les ressources.
- FAYAM (2024) baseline : un **TimeSeriesTransformer** HuggingFace entraîné sur Azure Functions 2019.
 - 33 clusters DBSCAN
 - Horizon : 120 min ; contexte : 240 min

Constat

FAYAM prédit
sans expliquer.

Or l'allocation
de ressources
FaaS est une décision
à enjeu opérationnel.

Fayam et al., 2024 ; Azure Functions 2019 dataset

Pourquoi expliquer la prédiction ?

3 motivations universelles

- **Confiance** — *Lipton (2018)* : un modèle opaque ne peut être déployé ; l'opérateur refuse de faire confiance à une boîte noire pour des décisions coûteuses.
- **Diagnostic** — *Rudin (2019)* : sans explication, impossible de savoir si un pic prédit à 3h du matin reflète un vrai pattern (batch job récurrent) ou un artifact de données → ressources gaspillées sans possibilité de corriger.
- **Conformité** — *EU AI Act (2024)* : la traçabilité des décisions automatisées est une obligation légale, pas un choix.

Stakeholders en jeu

- **Opérateur cloud** → prédictions précises pour allouer les ressources.
- **Développeur** → comprendre pourquoi son application ralentit.
- **Auditeur** → vérifier que les décisions automatiques sont justifiables.
- **Chercheur** → évaluer si l'explication reflète vraiment le calcul du modèle.

Panorama XAI temporel : trois familles

Post-hoc gradient

Sensibilité via $\partial f / \partial x$ — Exemples : Vanilla Gradients (Simonyan 2014), SmoothGrad (Smilkov 2017), Integrated Gradients (Sundararajan 2017), Grad-CAM (Selvaraju 2017).
Fidélité : locale, approximée.

Post-hoc perturbation

Marginalisation Shapley sur features masquées — Exemples : TimeSHAP, WindowSHAP, TsSHAP, SHAPformer.
Fidélité : statistique, coûteuse.

Intrinsèque — notre choix

Explication produite *dans* le forward pass — Exemples : CAM (Zhou 2016), Concept Bottleneck Models (Koh 2020), SoftCAM (Djoumessi & Berens 2025),
SoftCAM-Transformer H1 (ce travail).
Fidélité : par construction.

Sundararajan 2017 ; Lundberg & Lee 2017 ; Bento 2021 ; Nayebi 2023 ; Raykar 2023 ; Hertel 2025 ; Djoumessi & Berens 2025

Le problème central : attention $\neq$ explication

Problème

Les poids d'attention d'un Transformer **ne sont pas** garantis fidèles à la prédiction. Une attention différente peut produire *exactement la même sortie*.

- **Jain & Wallace 2019** : on construit des distributions d'attention *adversariales* sur LSTM+attention qui donnent la même prédiction.
- **Wiegrefe & Pinter 2019** : nuance — l'attention peut être informative *sous conditions*, mais la fidélité n'est pas garantie en général.
- **Serrano & Smith 2019** : étend la critique aux Transformers — zéroter les poids d'attention dominants *ne change souvent pas* la prédiction.

Verdict

Toute approche d'explication basée sur la cross-attention brute (TFT, attention raw) reste exposée à cette critique.

La promesse de l'explication intrinsèque

Post-hoc (SHAP, IG, GradCAM)

- Modèle entraîné *puis* expliqué après-coup.
- Approximation de ce que le modèle a fait.
- Pas de garantie de fidélité.

Intrinsèque (CAM, SoftCAM, H1)


- Explication *produite par* le modèle dans le forward pass.
- Coefficient algébrique exact.
- Fidélité **par construction**.

Verdict

Notre H1 : adapter le principe SoftCAM (carte d'évidence intrinsèque + régularisation ElasticNet) au TimeSeriesTransformer HuggingFace de FAYAM.

Rudin, 2019; Djoumessi & Berens, 2025; Zhou et al., 2016; Selvaraju et al., 2017

L'architecture SoftCAM-Transformer



$$M = \text{softmax}(\text{Linear}(\text{dec_output})) \quad (\text{carte d'évidence, } B \times 120 \times 240)$$
$$h_{ev} = M \cdot \text{enc_hidden} \quad (\text{représentation pondérée})$$
$$h = (1 - \text{mix}) \cdot \text{dec_output} + \text{mix} \cdot \text{LN}(h_{ev}) \quad (\text{mix calibré})$$

Vaswani et al., 2017 ; Djoumessi & Berens, 2025 ; Ba et al., 2016

La loss régularisée

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{forecast}}}_{\text{NLL Student-t}} + \alpha \|M\|_1 + \beta \|M\|_2^2 + \gamma H(M)$$

$\alpha \|M\|_1$ (Lasso)

Sparsité, sélection de positions.
→ quelques pas dominants.

$\beta \|M\|_2^2$ (Ridge)

Stabilité face aux corrélations temporelles.
→ évite l'effondrement sur 1 position.

$\gamma H(M)$ (entropie)

Pénalise l'uniformité de M.
→ M se concentre.

Interprétation

L'ElasticNet ($\alpha + \beta$) combinée à l'entropie (γ) façonne une carte d'évidence **sparse et stable** — condition de l'interprétabilité.

Zou & Hastie, 2005 ; Djoumessi & Berens, 2025

La première tentative : Run B

- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B**
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

Run B : Evidence Layer branchée à 30% dès l'époch 1

Configuration

- `evidence_mix` = 0.3 constant
- $\gamma = 10^{-3}$ constant
- **Aucun warm-up**
- Reste : architecture v2 conforme

Hypothèse de départ

Si l'architecture est correcte, l'optimisation devrait *trouver l'équilibre* entre `dec_output` et `h_evidence`.

Problème

$R^2 = -2.83$
Spearman = 0.33
Échec total

Diagnostic : la tête de sortie n'a pas le temps d'apprendre

Le mécanisme du collapse

- La tête `parameter_projection` est initialisée pour traiter `dec_output` *seul*.
- Lui imposer dès l'epoch 1 un mélange à 30% avec `h_evidence` non régularisé déstabilise toute la rétro-propagation.
- Conséquence : M ne se structure jamais — elle s'effondre sur une position arbitraire.

Analogie connue dans la littérature

Le même phénomène est documenté pour le **learning rate warm-up** : démarrer trop fort dégrade la convergence. La parade standard est d'introduire le signal *progressivement* sur les premières époques.


Verdict

Il faut **chauffer progressivement** le mix au lieu de l'imposer en dur.

He et al., 2019 (*Bag of Tricks*, CVPR) ; Smith, 2017 (cyclical learning rates)



Stratégie : entraînement progressif de la tête de sortie



Les 4 ingrédients de la recette B5

- 1 **Warm-up mix** : $0 \rightarrow 0.05$ sur les premières époques.
- 2 **Anneal γ** : $0 \rightarrow 10^{-3}$ progressif (entropie pénalisée tard).
- 3 **LayerNorm** sur h_{ev} avant le mix — aligne les statistiques.
- 4 **Mix final petit** (0.05) — dec_output reste dominant.

Ba et al., 2016 (LayerNorm) ; He et al., 2019 (warm-up)

Construction de la recette B5


- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5**
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

Run B2 : warm-up mix + anneal γ

Changement introduit

Schedules au lieu de constantes :

- $\text{mix} : 0 \rightarrow 0.3$ progressif
- $\gamma : 0 \rightarrow 10^{-3}$ progressif



Interprétation

Le décodeur est sauvé du collapse, mais h_{ev} reste *out-of-distribution* statistiquement vs dec_output.

Verdict

$R^2 = -1.97$ (+86 pp)
Spearman = 0.80
Progrès, mais insuffisant


Run B3 : LayerNorm sur $h_{evidence}$

Fix #4 architectural

Avant le mix, on aligne les statistiques :

$$\tilde{h}_{ev} = \text{LayerNorm}(h_{ev})$$

Les distributions de $\tilde{h}_{ev}$ et de dec_output deviennent compatibles.



Interprétation

M cesse de s'effondrer — max_weight passe de **0.97** à **0.06**.

Verdict

$R^2 = -1.59$ (+38 pp)
Spearman = 0.78
Toujours négatif


Ba et al., 2016 (LayerNorm)

Run B4 : la contre-expérience décisive

Test isolant le warm-up

On garde LayerNorm et anneal γ , mais on retire le warm-up :

- mix = 0.10 constant
- LayerNorm activé
- γ schedule conservé



Problème

$R^2 = -3.58$ (PIRE que B/B2/B3)
Spearman = 0.44

Verdict

Le **warm-up** est l'ingrédient critique.
Ni LayerNorm seul, ni anneal seul ne suffisent.

Run B5 : la recette complète

Warm-up mix
 $0 \rightarrow 0.05$

Anneal γ
 $0 \rightarrow 10^{-3}$

LayerNorm
sur h_{ev}

Mix final
 $= 0.05$


Résultat de l'addition des 4 ingrédients

$R^2 = 0.7130$ Spearman = 0.92
Les 5 fonctions du cluster ont $R^2 > 0$.

Verdict

Première recette qui converge — gate H1.C dépassé largement.

Synthèse : la séquence expérimentale $A \rightarrow B5$



Lecture en une phrase

Run A ($R^2=0.53$, baseline FAYAM pur) $\rightarrow$ Run B (-2.83 , collapse) $\rightarrow$ B2 (-1.97 , warm-up sauve le décodeur) $\rightarrow$ B3 (-1.59 , LayerNorm stabilise M) $\rightarrow$ B4 (-3.58 , contre-preuve) $\rightarrow$ **B5** ($+0.71$, **recette complète**).

Smith, 2017; He et al., 2019; Ba et al., 2016

La crise méthodologique : Fix #5


- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5**
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

L'anomalie : 9 valeurs de mix, le même R^2

Le test conduit

Sur le checkpoint B5, on lance un sweep `evidence_mix` à l'inférence sur 9 valeurs $\in [0.0, 1.0]$.

Attendu : courbe en cloche ou monotone.



Problème

Les 9 valeurs donnent
strictement le même
 $R^2 = 0.6646$.

Verdict

Un seul scénario explique cette platitude :
l'Evidence Layer est inactive à l'inférence.

Diagnostic dans le code HuggingFace

Localisation du bug

Dans `TimeSeriesTransformerForPrediction.generate()`, ligne 1679 (*transformers v4*) :

```
params = self.parameter_projection(dec_last_hidden[:, -1:])
```

L'appel *contourne* notre override `output_params` — la sortie est issue de `dec_output` sans mélange avec h_{ev} .

Le patch : Fix #5

Override de `generate()` dans la classe enfant. Une seule ligne changée :

```
params = self.output_params(dec_last_hidden[:, -1:])
```

Implications pour la validité scientifique

Ce qui n'était pas affecté

- `forward()` (entraînement) appelle *bien* `output_params` → tous les checkpoints sont valides.
- La loss régularisée et la convergence n'ont jamais utilisé la branche buggée.
- Les hypothèses validées en teacher-forced (H1.A, H1.D, H1.E) restent intactes.

Ce qui était affecté

- Toutes les métriques finales rapportées (R^2 , Spearman) jusqu'à la session 60 mesuraient `dec_output` seul, pas la branche h_{ev} .
- Les conclusions sur le choix de mix d'entraînement (B5 vs B6 vs B7) étaient prises sur des chiffres tronqués.


Verdict

Le bug est un **contrôle méthodologique a posteriori** qui renforce, plutôt qu'il n'invalide, la rigueur du protocole.

La trouvaille : dissociation entraînement / inférence

- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence**
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

Sweep mix d'inférence post Fix #5 — B5




Observations

- $R^2(\text{mix}=0) = 0.6646$ (M neutralisée)
- $R^2(\text{mix}=0.05) = 0.7130$ (mix entraîné)
- $R^2(\text{mix}=0.25) = \mathbf{0.7563}$ (pic)
- $R^2(\text{mix}=0.50) = 0.44$ (cassure)

Verdict

Le pic R^2 n'est pas au mix d'entraînement.
Le modèle est *mieux* avec plus de M.

Généralisation à B6 et B7 — un pattern empirique



Pattern empirique

Run	Mix entraîné	Mix optimal inférence	Ratio
B5	0.05	0.25	$\times 5$
B6	0.10	0.50	$\times 5$
B7	0.15	0.50	$\times 3.3$

Verdict

L'optimum d'inférence est systématiquement $\approx 5 \times$ le mix d'entraînement.

Interprétation : pourquoi cette dissociation ?

Pendant l'entraînement à $\text{mix} = 0.05$

- 95% du signal prédictif passe par `dec_output` — la tête se calibre principalement sur cette branche.
- h_{ev} apprend *sous contrainte* ElasticNet + entropie — elle ne peut pas se permettre de patterns qui ne correspondent qu'à une seule fonction du cluster.
- Résultat : h_{ev} encode des patterns **sparses, stables, cluster-level** (cf. H1.D, Pearson = 0.992).


À l'inférence

- Donner plus de poids ($\text{mix} = 0.25$) à un signal **stable cluster-level** améliore la prédiction.
- Au-delà de $\text{mix} = 0.25$: le compromis casse, `dec_output` perd trop d'influence.

Interprétation

Trouvaille originale : la **dissociation entraînement / inférence** est une propriété de la régularisation, pas un artefact.

Décomposition du gain final




Quatre paliers de la contribution H1

- **FAYAM original** : $R^2 = 0.3701$ — baseline mémoire.
- **Run A** (notre repro pure) : $R^2 = 0.5299$ — +15.98 pp.
- **B5, mix=0 inférence** : $R^2 = 0.6646$ — +13.46 pp régularisation seule.
- **B5, mix=0.25 inférence** : $R^2 = 0.7563$ — +9.17 pp utilisation effective de M.

Verdict

Total : +38.62 pp absolu vs FAYAM original.

Comparaison à la baseline et au TFT



* TFT non mesuré sur nos données — comparaison architecturale

Positionnement

- **FAYAM** ($R^2 = 0.37$) — baseline mémoire, opaque.
- **TFT** (Lim 2019) — Transformer interprétable, mais attention non garantie fidèle (Jain & Wallace).
- **B5 + mix=0.25** ($R^2 = 0.7563$) — explication fidèle *par construction* et précision supérieure.

Verdict

Notre architecture explique
fidèlement et **dépasse** la baseline.

Lim et al., 2019 (TFT); Jain & Wallace, 2019

Validation des hypothèses H1.A–H1.G

- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G**
- 7 Position, limites et perspectives

Méthodologie de validation

7 hypothèses formulées *avant* exécution (pré-enregistrement).


ID	Hypothèse	Critère
H1.A	Maxima de M au pic horaire cohérent	corr. temporelle
H1.B	M corrèle aux cross-attentions du décodeur	Pearson > 0
H1.C	Précision conservée malgré l'Evidence Layer	$R^2 \geq 0.30$; $Sp \geq 0.85$
H1.D	M cohérente intra-cluster (5 fonctions)	Pearson moyen
H1.E	M plus piquée pour les bonnes prédictions	entropie de M
H1.F	Masquer top- k de M dégrade R^2 (comp.)	$\Delta R^2 < 0$
H1.G	Garder top- k de M préserve R^2 (suff.)	$\Delta R^2 \approx 0$

Référence métrique

H1.F/G : définitions **comprehensiveness/sufficiency** d'ERASER (DeYoung 2020). Distinction fidélité / plausibilité : Jacovi & Goldberg 2020.

DeYoung et al., 2020 (ERASER, ACL) ; Jacovi & Goldberg, 2020 (ACL)

H1.C : non-dégradation de la précision



Seuils pré-enregistrés

- $R^2 \geq 0.30$
- Spearman ≥ 0.85

Résultats B5 + mix=0.25

- $R^2 = 0.7563$ (+0.4563)
- Spearman = 0.9169 (+0.0669)

Verdict

Marge très large sur les deux gates.

H1.D : cohérence intra-cluster

Pearson hors-diagonale (5 fonctions, Cluster 4)

Entre les 5 matrices M :

Pearson = 0.992


Interprétation

Les 5 fonctions produisent des M quasi-identiques — M capture le pattern *cluster-level*, pas des idiosyncrasies individuelles.

Problème

Nuance honnête : confondant partiel — paramètres partagés + inputs similaires par construction du clustering. Test inter-clusters non réalisé.

H1.E : sparsité $\leftrightarrow$ précision



Corrélation Spearman


Entre le R^2 par fonction et l'entropie moyenne des lignes de M :

$$\rho = -0.80$$

Interprétation

Plus M est **concentrée** (entropie basse), **meilleure** la prédiction. La régularisation ElasticNet + entropie pousse exactement dans ce sens.

H1.F : comprehensiveness (à mix=0.25)



Protocole

On cache les cases les plus importantes de M , une par une, et on observe si la précision se dégrade.

Résultats


- Cacher 1 case : -1.13% de précision
- Cacher 10 cases : -3.27%
- Tout cacher : -5.37% au maximum

Verdict

M ne pèse que 25% dans le calcul final :
perdre 5.37% sur 25% possibles =
21%.

M guide bien la prédiction — son
rôle est réel.

H1.G : sufficiency (à $\text{mix}=0.25$)



Test

On garde seulement les top-k positions de M (renormalisées), on masque le reste, et on mesure la préservation de la qualité.

Résultats

- Préservation @ k=1 : **97.13%**
- Préservation @ k=5 : 97.13%
- Préservation @ k=10 : 97.89%
- Préservation @ k=50 : 100.23%

Verdict

Une seule position suffit à 97% — M est **extrêmement sparse**.

DeYoung et al., 2020

H1.A et H1.B : résultats nuancés

H1.A ✓ indicatif — M pointe le pic 17-19h ?

37% des $\text{argmax}(M)$ tombent dans la fenêtre 17-19h vs 25% baseline uniforme.

Limite honnête : ce test ne vérifie pas l'alignement diagonal complet (M pour prédire 03h devrait pointer vers 03h historique). Test non réalisé.

H1.B △ reframé — $M \leftrightarrow$ cross-attention ?

Spearman moyen ($\text{argmax } M, \text{argmax } CA$) = 0.16 — hétérogène par fonction.

Lecture : comparer M à la cross-attention est circulaire — la cross-attention n'est pas une référence fiable (Jain & Wallace). La divergence est **attendue** et **souhaitable**.

Verdict

Ces deux hypothèses sont à présenter comme **compléments d'analyse**, pas comme tests centraux.

Jain & Wallace, 2019 ; Serrano & Smith, 2019

Position, limites et perspectives

- 1 Contexte, état de l'art et architecture
- 2 La première tentative : Run B
- 3 Construction de la recette B5
- 4 La crise méthodologique : Fix #5
- 5 La trouvaille : dissociation entraînement / inférence
- 6 Validation des hypothèses H1.A–H1.G
- 7 Position, limites et perspectives

La question que vous pourrez me poser

Critique anticipée

« Vous avez réglé mix après l'entraînement. N'est-ce pas une explication post-hoc déguisée ? »

Ma réponse

- Mix est un réglage **global et unique** — comme la température d'un LLM, il ne change pas d'une prédiction à l'autre.
- La fidélité de M au calcul tient dès que $\text{mix} > 0$, quelle que soit la valeur choisie.
- Une fois $\text{mix} = 0.25$ fixé, le modèle est **entièrement déterministe** à l'inférence.
- La dissociation entraînement/inférence est une **observation empirique documentée**, pas une correction de dernière minute.

Verdict

Je parlerai de **self-explainability calibrée** dans le mémoire — honnête sur la dissociation, mais pas post-hoc.

Rudin, 2019 ; Lipton, 2018

Ce que ce travail ne fait pas encore

- **Un seul run (seed 998)** — je n'ai pas relancé plusieurs fois, donc je ne connais pas la variance de mes résultats.
- **Un seul cluster testé (C4)** — les autres ne convergent pas même en baseline ; les comparer aurait introduit un biais.
- **H1.A incomplet** — j'ai vérifié les pics 17h–19h, mais pas l'alignement heure par heure sur les 24h.
- **H1.D : corrélation attendue** — les fonctions du même cluster partagent des paramètres et des profils proches ; la cohérence était en partie prévisible.
- **H1.F avec renormalisation** — après masquage, j'ai renormalisé M, ce qui atténue l'effet mesuré. Le test brut reste à faire.

Interprétation

Ces points ne remettent pas H1 en cause — ils balisent honnêtement ce qui reste ouvert.

Ce que j'attends de vous aujourd'hui

Ce que je propose — vos avis ?

- 1 **Configuration B5 + mix=0.25** : est-ce que vous la validez comme version finale ?
- 2 **H1.A incomplet** : le test diagonal (heure par heure sur 24h) manque — est-ce bloquant pour la soutenance ?
- 3 « *Calibrated self-explainability* » : ce terme vous semble-t-il défendable dans le mémoire ?

Ce qu'il me reste à décider avec vous

- 1 Faut-il ajouter une comparaison post-hoc (TimeSHAP / IG) ou H1 se suffit-il ?
- 2 Quand pouvez-vous me donner un retour sur le premier draft du chapitre H1 ?

Bento et al., 2021 (TimeSHAP) ; Sundararajan et al., 2017 (Integrated Gradients)

Merci de votre attention

Questions ?